



MÁSTER EN DATA SCIENCE & BUSINESS ANALYTICS
PRESENCIAL

ANÁLISIS DEL MERCADO INMOBILIARIO Y DETECCIÓN TEMPRANA DE GENTRIFICACIÓN EN LA CIUDAD DE MADRID

TFM elaborado por:

- Samantha Barone Guerra
- Gaspar Campuzano Gallego
- Jorge Galeano Maté
- Andrea Guerra Arguinzones

Tutor de TFM: Gabriel Valverde Castilla

– Madrid, 20 de octubre de 2025 –

Índice de contenido

1. RESUMEN / ABSTRACT	6
2. INTRODUCCIÓN Y ANTECEDENTES.....	7
2.1. CONTEXTO DEL MERCADO INMOBILIARIO EN MADRID	7
2.2. PROBLEMAS DE ACCESIBILIDAD Y GENTRIFICACIÓN	7
2.3. PROPÓSITO DEL ESTUDIO.....	8
2.4. MARCO CONCEPTUAL	9
2.5. MERCADO INMOBILIARIO Y DINÁMICA DE PRECIOS.	9
2.6. ACCESIBILIDAD A LA VIVIENDA E INDICADORES.....	10
2.7. GENTRIFICACIÓN: TEORÍA Y MEDICIÓN.	11
2.8. CIENCIA DE DATOS APLICADA AL MERCADO INMOBILIARIO.	12
3. OBJETIVOS.....	13
3.1. OBJETIVOS GENERALES:	13
3.2. OBJETIVOS ESPECÍFICOS:	14
4. METODOLOGÍA	14
4.1. RECOLECCIÓN E INTEGRACIÓN DE DATOS	14
4.1.1. Fuentes de datos	15
4.1.2. Extracción automatizada de datos desde Idealista	17
4.1.3. Unificación y enriquecimiento de los anuncios	20
4.1.4. Integración con fuentes oficiales.....	20
4.1.5. Proyección retrospectiva de precios.....	21
4.1.5.1. Métodos de ajuste	21
4.1.5.2. Validación visual del método	22
4.2. ANÁLISIS EXPLORATORIO DE DATOS (EDA).....	25
4.2.1. Preparación y calidad de los datos	25
4.2.2. Distribuciones univariantes	27
4.2.3. Análisis por distrito	29
4.2.4. Correlaciones.....	32
4.2.5. Evolución temporal (2011-2024)	34
4.2.6. Implicaciones para el modelado	36
4.3. ANÁLISIS DEL MERCADO Y MODELADO PREDICTIVO	37
4.3.1. Modelos predictivos	37
4.3.1.1. Preparación del dataset y codificación de variables.....	37
4.3.1.2. División temporal de los datos	38
4.3.1.3. Pipeline de modelado	38

4.3.1.4.	Selección de modelos base	39
4.3.1.5.	Optimización de parámetros	41
4.3.1.6.	Entrenamiento final y evaluación	42
4.4.	DISEÑO DEL ÍNDICE DE ACCESIBILIDAD A LA VIVIENDA (IAV)	47
4.4.1.	<i>Enfoque conceptual</i>	47
4.4.2.	<i>IAV de Compra (basado en precio de venta por metro cuadrado)</i>	48
4.4.3.	<i>IAV de Alquiler (basado en precio de alquiler €/m²)</i>	49
4.4.4.	<i>Marco de referencia internacional</i>	50
4.4.5.	<i>Nivel de esfuerzo y sostenibilidad financiera</i>	51
4.5.	EXPLORACIÓN DE GENTRIFICACIÓN	51
4.5.1.	<i>Representación latente del parque residencial</i>	52
4.5.2.	<i>Agrupamiento en el espacio latente</i>	52
4.5.3.	<i>Integración espacial y enfoque analítico</i>	54
4.5.4.	<i>Síntesis metodológica</i>	54
4.6.	INTERFAZ WEB INTERACTIVA	54
4.6.1.	<i>Arquitectura y funcionamiento</i>	55
4.6.2.	<i>Módulos analíticos avanzados</i>	56
4.6.3.	<i>Usabilidad y experiencia de usuario</i>	61
4.6.4.	<i>Innovación metodológica y valor añadido</i>	61
5.	RESULTADOS	62
5.1.	EVALUACIÓN DE LOS MODELOS PREDICTIVOS	62
5.2.	RESULTADOS DEL IAV	63
5.2.1.	<i>Panorama general</i>	64
5.2.2.	<i>Esfuerzo económico y sostenibilidad</i>	64
5.2.3.	<i>Accesibilidad por distrito (alquiler)</i>	65
5.2.4.	<i>Accesibilidad por distrito (compra)</i>	66
5.2.5.	<i>Comparativa compra vs alquiler</i>	67
5.2.6.	<i>Evolución temporal (alquiler)</i>	68
5.2.7.	<i>Accesibilidad y esfuerzo económico en la compra de vivienda</i>	70
5.2.8.	<i>Comparación del IAV con variables socioeconómicas y demográficas</i>	70
5.3.	PATRONES DE GENTRIFICACIÓN Y TIPOLOGÍAS DETECTADAS	72
5.3.1.	<i>Tipologías residenciales identificadas</i>	72
5.3.2.	<i>Distribución espacial y segmentación territorial</i>	74
5.3.3.	<i>Tasa de gentrificación por composición de clústeres</i>	75
5.3.4.	<i>Revisión del modelo e inclusión del clúster 3</i>	76
5.3.5.	<i>Casos destacados</i>	77

5.3.6.	<i>Síntesis de resultados</i>	78
6.	DISCUSIÓN	78
6.1.	IMPLICACIONES PARA LA PLANIFICACIÓN URBANA	79
6.2.	LIMITACIONES Y DESAFÍOS METODOLÓGICOS.....	80
6.3.	APORTE DE VALOR.....	81
6.4.	FUTURAS LÍNEAS DE INVESTIGACIÓN	81
7.	CONCLUSIONES	82
7.1.	CUMPLIMIENTO DE LOS OBJETIVOS DEL ESTUDIO	82
7.2.	CONTRIBUCIÓN DEL ESTUDIO	83
7.3.	REFLEXIÓN FINAL.....	84
8.	BIBLIOGRAFÍA	84
9.	ANEXOS	88
9.1.	ANEXO A. PROCESO TÉCNICO DE EXTRACCIÓN DE DATOS DESDE IDEALISTA	88
9.1.1.	<i>Objetivo</i>	88
9.1.2.	<i>Entorno de ejecución</i>	88
9.1.3.	<i>Variables de entorno</i>	88
9.1.4.	<i>Parámetros de ejecución</i>	89
9.1.5.	<i>Datos extraídos</i>	89
9.1.6.	<i>Salidas del proceso</i>	89
9.1.7.	<i>Estrategias anti-bloqueo</i>	89
9.1.8.	<i>Buenas prácticas</i>	90
9.2.	ANEXO B. REPOSITORIO DE GITHUB	90

Índice de Figuras

FIGURA 1.	DIAGRAMA DE FLUJO DEL TRABAJO.	9
FIGURA 2.	DIAGRAMA DE FLUJO DEL PROGRAMA DE WEB SCRAPING.	19
FIGURA 3.	EVOLUCIÓN DEL PRECIO DE VENTA MEDIO PROYECTADO POR DISTRITO Y AÑO.....	22
FIGURA 4.	EVOLUCIÓN DEL PRECIO DE ALQUILER MEDIO PROYECTADO POR DISTRITO Y AÑO.	23
FIGURA 5.	COMPARACIÓN DE PRECIOS DE VENTA REALES Y PROYECTADOS POR DISTRITO DESPUÉS DEL AJUSTE (2011-2024).	24
FIGURA 6.	COMPARACIÓN DE PRECIOS DE ALQUILER REALES Y PROYECTADOS POR DISTRITO DESPUÉS DEL AJUSTE (2011-2024).	24
FIGURA 7.	BOXPLOT DE PRECIOS POR OPERACIÓN. (IZQUIERDA: VENTA; DERECHA: ALQUILER).	26
FIGURA 8.	BOXPLOT DE PRECIOS, SIN VALORES ATÍPICOS, POR OPERACIÓN. (IZQUIERDA: VENTA; DERECHA: ALQUILER).	26

FIGURA 9. DISTRIBUCIÓN DEL PRECIO DE VENTA EN MADRID (2011-2024).	27
FIGURA 10. DISTRIBUCIÓN DEL PRECIO DE ALQUILER EN MADRID (2011-2024).	28
FIGURA 11. DISTRIBUCIÓN DEL PRECIO POR TIPO DE VIVIENDA EN MADRID (2011-2024).	28
FIGURA 12. BOXPLOT DE PRECIO MEDIO DE VENTA POR DISTRITO, ENTRE 2011 Y 2024.	29
FIGURA 13. BOXPLOT DE PRECIO MEDIO DE ALQUILER POR DISTRITO, ENTRE 2011 Y 2024.	30
FIGURA 14. PRECIOS MEDIANOS DE VENTA POR METRO CUADRADO POR DISTRITO (2011-2024).	31
FIGURA 15. PRECIOS MEDIANOS DE ALQUILER POR METRO CUADRADO POR DISTRITO (2011-2024).	31
FIGURA 16. TAMAÑO MEDIO DE VIVIENDA POR DISTRITO EN MADRID (2011-2024).	32
FIGURA 17. CORRELACIÓN DE PEARSON.	33
FIGURA 18. CORRELACIÓN DE SPEARMAN.	33
FIGURA 19. EVOLUCIÓN ANUAL DEL PRECIO MEDIANO EN VENTA (2011-2024).	34
FIGURA 20. EVOLUCIÓN ANUAL DEL PRECIO MEDIANO EN ALQUILER (2011-2024).	35
FIGURA 21. NUBE DE PALABRAS CON LOS TÉRMINOS MÁS FRECUENTES EN LAS DESCRIPCIONES DE LOS ANUNCIOS (2011-2024).	36
FIGURA 22. RELACIÓN ENTRE PRECIOS REALES Y PREDICHOS DE VENTA (TEST 2023-2024).	43
FIGURA 23. RELACIÓN ENTRE PRECIOS REALES Y PREDICHOS DE ALQUILER (TEST 2023-2024).	44
FIGURA 24. DISTRIBUCIÓN DEL ERROR RELATIVO EN VENTA POR RANGO DE PRECIOS.	44
FIGURA 25. DISTRIBUCIÓN DEL ERROR RELATIVO EN ALQUILER POR RANGO DE PRECIOS.	45
FIGURA 26. IMPORTANCIA RELATIVA DE LAS VARIABLES EN EL MODELO LGBM DE VENTA.	45
FIGURA 27. IMPORTANCIA RELATIVA DE LAS VARIABLES EN EL MODELO LGBM DE ALQUILER.	46
FIGURA 28. DIAGRAMA DE FLUJO DE ELABORACIÓN DE CLÚSTERES.	53
FIGURA 29. STREAMLIT: MÉTRICAS PRINCIPALES.	57
FIGURA 30. STREAMLIT: MAPA POR DISTRITO DE MADRID.	58
FIGURA 31. STREAMLIT: TABLA DE DATOS Y EVOLUCIÓN TEMPORAL.	58
FIGURA 32. STREAMLIT: CLÚSTERES VISUALIZADOS CON UMAP.	59
FIGURA 33. MAPA DE TASA DE GENTRIFICACIÓN POR DISTRITO CON K-MEANS.	60
FIGURA 34. STREAMLIT: PREDICCIÓN DE PRECIOS SEGÚN CARACTERÍSTICAS.	60
FIGURA 35. DIAGRAMA DE FLUJO DEL FUNCIONAMIENTO DE LA INTERFAZ WEB DE STREAMLIT.	62
FIGURA 36. ÍNDICE DE ACCESIBILIDAD MEDIA POR DISTRITOS – ALQUILER.	65
FIGURA 37. ÍNDICE DE ACCESIBILIDAD MEDIA POR DISTRITOS – COMPRA.	66
FIGURA 38. DISTRIBUCIÓN DEL IAV COMPRA VS ALQUILER.	67
FIGURA 39. EVOLUCIÓN DEL IAV POR DISTRITO - ALQUILER	69
FIGURA 40. CORRELACIÓN DE SPEARMAN CON IAV.	71
FIGURA 41. DISTRIBUCIÓN DE CLÚSTERES EN EL ESPACIO LATENTE (UMAP).	73
FIGURA 42. DISTRIBUCIÓN ESPACIAL DE LOS CLÚSTERES RESIDENCIALES POR DISTRITO	74
FIGURA 43. TASA DE GENTRIFICACIÓN POR DISTRITO SEGÚN DOS MÉTODOS: COMPOSICIÓN DE CLÚSTERES Y PRECIO MEDIO RELATIVO.	76
FIGURA 44. TASA DE GENTRIFICACIÓN REVISADA (MODELO 0,1,3,4).	77

FIGURA 45. DIAGRAMA DEL REPOSITORIO DE GITHUB.....90

Índice de Tablas

TABLA 1. INDICADORES INDIRECTOS UTILIZADOS PARA LA DETECCIÓN DE GENTRIFICACIÓN EN MADRID.....12

TABLA 2. ORÍGENES DE DATOS.....15

TABLA 3. DIVISIÓN TEMPORAL DE LOS DATOS.....38

TABLA 4. RESULTADOS DE VALIDACIÓN CRUZADA DE MODELO DE VENTA (2015-2022).40

TABLA 5. RESULTADOS DE VALIDACIÓN CRUZADA DE MODELO DE ALQUILER (2015-2022).....41

TABLA 6. MEJORES PARÁMETROS PARA MODELOS PREDICTIVOS DE VENTA Y ALQUILER.42

TABLA 7. RESULTADOS DE PRUEBA DE VENTA (2023-2024).42

TABLA 8. RESULTADOS DE PRUEBA DE ALQUILER (2023-2024).43

TABLA 9. CLÚSTERES DEFINIDOS POR EL MODELO K-MEANS.....72

1. Resumen / Abstract

Resumen:

El estudio analiza la evolución del mercado inmobiliario madrileño y las desigualdades territoriales en el acceso a la vivienda entre 2011 y 2024 mediante ciencia de datos.

Se integraron datos de Idealista con fuentes del ayuntamiento y del INE, generando más de 140.000 registros. Se entrenaron modelos predictivos de precios con LightGBM optimizados con Optuna, que alcanzaron un $R^2 > 0,9$ y un MAPE $< 5\%$, mostrando alta precisión. Se diseñó también un Índice de Accesibilidad a la Vivienda (IAV), que mide la capacidad de los hogares para afrontar el coste de compra o alquiler.

Los resultados evidencian una inaccesibilidad estructural a la compra y una accesibilidad aparente al alquiler, sostenida por rentas compartidas. El análisis territorial del IAV muestra un claro gradiente norte-sur y el clustering revela patrones de gentrificación en expansión. El trabajo demuestra la utilidad del aprendizaje automático para una planificación urbana basada en evidencia.

Palabras clave:

Accesibilidad a la vivienda, gentrificación, ciencia de datos, análisis, modelo predictivo, desigualdad urbana, Madrid.

Abstract:

The study analyzes the evolution of the Madrid real estate market and territorial inequalities in access to housing between 2011 and 2024 using data science.

Data from Idealista was integrated with sources from the city council and INE, generating more than 140,000 records. Price prediction models were trained with LightGBM optimized with Optuna, achieving an $R^2 > 0.9$ and a MAPE $< 5\%$, demonstrating high accuracy. A Housing Affordability Index (HAI) was also designed, which measures households' ability to meet the cost of purchase or rent.

The results show structural inaccessibility to purchase and apparent accessibility to rent, sustained by shared incomes. The territorial analysis of the HAI shows a clear north-south gradient, and clustering reveals patterns of expanding gentrification. The work demonstrates the usefulness of machine learning for evidence-based urban planning.

Keywords:

Housing affordability, gentrification, data science, analysis, predictive model, urban inequity, Madrid.

2. Introducción y antecedentes

Esta sección presenta el contexto urbano, económico y social que enmarca el estudio sobre el acceso a la vivienda y la detección de gentrificación en Madrid. Además del análisis del mercado inmobiliario, el propósito del trabajo es comprender las transformaciones territoriales y sus implicaciones sociales, especialmente en términos de desigualdad, desplazamiento y accesibilidad residencial. A través de una revisión del mercado de la vivienda, las dinámicas socioeconómicas y los enfoques conceptuales relevantes, se establecen las bases que orientan el desarrollo metodológico del trabajo.

2.1. Contexto del mercado inmobiliario en Madrid

En las últimas décadas, el mercado inmobiliario en Madrid ha estado sometido a una fuerte presión en los precios, tanto en la compraventa como en alquiler. Según el Instituto Nacional de Estadística (INE), la variación anual del Índice de Precios de Vivienda (IPV) en España alcanzó un 12,7 % en el segundo trimestre de 2025, reflejando una tendencia sostenida de encarecimiento del mercado residencial. (INE, 2025) Este comportamiento responde a diversos factores: el crecimiento demográfico, la atracción de capital extranjero, la expansión del turismo urbano y el papel de la ciudad como principal motor económico y urbano de España. Solo en Madrid, el turismo internacional aumentó aproximadamente un 74% en los últimos diez años. (Expansión, 2025)

La estructura urbana de Madrid combina áreas históricas en proceso de regeneración, barrios consolidados de alta densidad y zonas periféricas sujetas a nuevas dinámicas de desarrollo. Este mosaico territorial ha generado desigualdades significativas en el acceso a la vivienda, con distritos donde los precios superan ampliamente la renta media disponible de los hogares.

A esta situación se suman fenómenos recientes como la expansión de las plataformas de alquiler turístico (como Airbnb), la mayor financiación hipotecaria y los cambios sociodemográficos, que intensifican la presión sobre el mercado y favorecen procesos de revalorización urbana y desplazamiento residencial. (Fernández Ochoa, 2025)

2.2. Problemas de accesibilidad y gentrificación

El acceso a la vivienda constituye uno de los principales desafíos urbanos en Madrid. En numerosos distritos, la proporción del ingreso de los hogares destinada al alquiler o a la hipoteca supera el 30

% de la renta disponible —umbral recomendado por organismos internacionales—, generando situaciones de sobreendeudamiento y exclusión residencial.

Este fenómeno afecta con especial intensidad a jóvenes, inmigrantes y familias de bajos ingresos, que enfrentan crecientes obstáculos para la entrada a una vivienda adecuada. Paralelamente, los procesos de gentrificación se han consolidado en los distritos céntricos, impulsados por la revalorización del suelo, la inversión privada y la sustitución del tejido social tradicional.

Desde la perspectiva económica, N. Smith introdujo la teoría del *rent gap*, entendida como la diferencia entre el valor que genera actualmente un suelo o inmueble y el valor que podría alcanzar si se destinara a un uso más rentable. Cuanto mayor es esta brecha, mayor es el incentivo para invertir y transformar el entorno urbano. Este proceso se amplifica en contextos de desinversión, envejecimiento del parque inmobiliario y acceso al crédito. (Smith, 1979)

Por otro lado, S. Zukin amplió la mirada al resaltar la dimensión cultural y simbólica de la gentrificación: la creación de imaginarios urbanos positivos y el apoyo estatal a políticas de renovación impulsan la llegada de nuevos residentes con mayor poder adquisitivo. (Zukin, 1987)

Investigaciones más recientes han ampliado la mirada hacia los factores sociodemográficos. En un estudio comparativo en grandes áreas metropolitanas de Estados Unidos, se demostró cómo la gentrificación se asocia a incrementos en el nivel educativo y profesional de los nuevos residentes, aumento en los precios de la vivienda y desplazamiento de poblaciones vulnerables hacia la periferia. (Schinasi, y otros, 2021)

En el caso de Madrid, barrios como Centro, Chamberí o Arganzuela ilustran estos procesos, combinando un notable crecimiento del alquiler turístico, la revalorización de inmuebles y la transformación del perfil social de sus habitantes. (Fernández Ochoa, 2025)

2.3. Propósito del estudio

El presente trabajo parte de la premisa de que comprender el mercado inmobiliario madrileño requiere un enfoque integrador que combine la dimensión económica, social y territorial. Para ello, se articulan dos perspectivas complementarias: una **visión cuantitativa**, centrada en la predicción de precios y en la construcción de un indicador sintético de accesibilidad, y una **visión social y espacial**, orientada a detectar señales tempranas de gentrificación mediante el análisis de datos del mercado y variables socioeconómicas. Este enfoque dual busca generar evidencia empírica que contribuya al debate académico y a la formulación de políticas públicas de vivienda y planificación

urbana, favoreciendo la identificación de territorios en riesgo de exclusión residencial o transformación social acelerada.

2.4. Marco conceptual

El estudio se sitúa en la intersección entre la economía de la vivienda, los estudios urbanos y la ciencia de datos aplicada al análisis territorial. Se presentan los conceptos teóricos y operativos que orientan la investigación, articulados en torno a tres dimensiones complementarias: la dinámica del mercado inmobiliario, los indicadores de accesibilidad habitacional y los procesos de transformación urbana (gentrificación).

El siguiente esquema conceptual sintetiza la estructura teórica del trabajo y las relaciones entre sus componentes fundamentales.




Figura 1. Diagrama de flujo del trabajo.

2.5. Mercado inmobiliario y dinámica de precios.

El mercado de la vivienda en España, y en particular en la ciudad de Madrid, se caracteriza por una elevada volatilidad en los precios y una fuerte presión sobre el acceso a la vivienda. Factores como la localización, la tipología del inmueble, el nivel socioeconómico de los hogares y la oferta de vivienda nueva o reformada determinan la evolución de los precios, tanto en compraventa como en alquiler.

En este contexto, la predicción de precios inmobiliarios se ha consolidado como un campo de aplicación recurrente de modelos estadísticos y de aprendizaje automático. Estas metodologías permiten integrar múltiples variables como la superficie, el número de habitaciones, las características del edificio o el entorno urbano para generar estimaciones ajustadas a realidades locales. Su utilidad trasciende el ámbito de la inversión inmobiliaria y ofrece un recurso valioso para la planificación urbana y la formulación de políticas públicas. (Martín Agüero, 2025)

2.6. Accesibilidad a la vivienda e indicadores.

El concepto de accesibilidad a la vivienda se refiere a la capacidad de los hogares para acceder a un alojamiento adecuado sin comprometer de manera excesiva sus recursos económicos. En la literatura internacional, esta accesibilidad suele medirse mediante indicadores como el esfuerzo financiero (*housing cost burden*), entendido como la proporción de la renta disponible destinada al pago de la vivienda. (Acolin & Reina, 2022)

Diversos organismos, como la OECD y ONU-Hábitat, establecen que el gasto en vivienda no debe superar el 30–35 % de los ingresos mensuales del hogar, umbral a partir del cual se considera una situación de sobrecarga o vulnerabilidad económica. (UN-Habitat, 2024; Organisation for Economic Co-operation and Development (OECD), 2023)

En España, organismos como el Ministerio de Transportes y Movilidad Sostenible (MITMA) han desarrollado métricas de esfuerzo de acceso, aunque no existe un índice sintético único que integre simultáneamente precio por metro cuadrado, superficie mínima habitable y renta media disponible de los hogares, lo que dificulta la comparación territorial y temporal de la accesibilidad habitacional. (Mullor Gómez, 2007)

En este contexto, en el presente trabajo se propone la construcción de un Índice de Accesibilidad a la Vivienda (IAV) adaptado al contexto madrileño, con el objetivo de representar de manera más clara las desigualdades territoriales y socioeconómicas en el acceso a la vivienda. Otras fórmulas, como el índice de esfuerzo para la adquisición inmobiliaria, no tienen en cuenta el mínimo indispensable para una vivienda digna. Este indicador busca aportar una herramienta transparente y basada en evidencia, que facilite la identificación de territorios en riesgo de exclusión residencial y sirva de apoyo para el diseño de políticas públicas orientadas a la vivienda asequible.

2.7. Gentrificación: teoría y medición.

La gentrificación se entiende como un proceso de transformación urbana y social, caracterizado por la llegada de nuevos residentes de mayor nivel adquisitivo que provocan la revalorización de los inmuebles y el desplazamiento de la población original.

Los enfoques clásicos, como la teoría del *rent gap* de Smith y la perspectiva cultural de Zukin, explican este fenómeno como el resultado de la brecha entre el valor actual del suelo y su potencial de rentabilidad, impulsada por la inversión y la resignificación simbólica del espacio urbano. (Smith, 1979; Zukin, 1987) Estas ideas se complementan con aproximaciones empíricas contemporáneas basadas en datos de precios, censos y plataformas digitales, que permiten identificar patrones socioespaciales asociados a la gentrificación. (Schinasi et al., 2021)

En este trabajo se emplean indicadores indirectos que actúan como variables representativas de la gentrificación, reflejando sus dimensiones económicas, sociales y demográficas. Aunque no miden la gentrificación de manera directa, permiten inferir su presencia y magnitud a partir de la evolución de precios, niveles de renta, características educativas y cambios en el uso residencial. (Smith, 1979; Zukin, 1987; Schinasi, y otros, 2021)

Para su detección temprana, en este trabajo se consideran indicadores indirectos como los mostrados en la Tabla 1.

Tabla 1. Indicadores indirectos utilizados para la detección de gentrificación en Madrid

INDICADOR	DESCRIPCIÓN	INTERPRETACIÓN SOCIOECONÓMICA
INCREMENTO DE PRECIOS DE VENTA Y ALQUILER SUPERIORES A LA MEDIA DISTRITAL	Mide la revalorización del mercado inmobiliario en relación con la media de la ciudad.	Un aumento sostenido de precios evidencia presión del capital e inversión selectiva, generando desplazamiento indirecto de residentes.
CRECIMIENTO DEL NÚMERO DE VIVIENDAS TURÍSTICAS	Captura la conversión de vivienda habitual en alojamiento temporal.	Pone de manifiesto la sustitución del uso residencial por el turístico y la pérdida de vivienda permanente.
INCREMENTO DEL NIVEL EDUCATIVO Y DE LA RENTA MEDIA DISTRITAL	Evalúa el reemplazo progresivo de la población de menor poder adquisitivo por hogares de mayores ingresos y formación.	Indica cambio en la composición social del territorio.
CAMBIOS EN EL LENGUAJE DE LOS ANUNCIOS INMOBILIARIOS	Analiza la aparición de términos asociados a estilos de vida aspiracionales ("reformado", "diseño", "zona emergente").	Representa la resignificación simbólica del barrio y su valorización discursiva.
VARIACIONES OBSERVADAS EN CENSOS Y PADRONES (PÉRDIDA DE POBLACIÓN ENVEJECIDA, AUMENTO DE HOGARES PEQUEÑOS)	Mide transformaciones poblacionales asociadas a la llegada de nuevos residentes.	Refleja desplazamiento demográfico y cambios en la estructura del hogar.

2.8. Ciencia de datos aplicada al mercado inmobiliario.

El desarrollo de modelos predictivos en el ámbito inmobiliario se ha consolidado a través de enfoques como los Modelos de Valoración Automatizada (AVM), ampliamente utilizados en mercados como el estadounidense (Zillow, Redfin). Estos modelos integran algoritmos de regresión,

árboles de decisión, técnicas de boosting (XGBoost) o redes neuronales, logrando una elevada precisión en la estimación de precios.

En el contexto español, la limitación de acceso a bases de datos estructuradas ha impulsado el uso de *web scraping* sobre portales inmobiliarios como Idealista, complementado con fuentes oficiales del Ayuntamiento y del INE.

Las técnicas de aprendizaje automático no supervisado, como el clustering o la reducción de dimensionalidad, permiten identificar patrones espaciales y tipológicos en la vivienda. Por su parte, el procesamiento de lenguaje natural (NLP) facilita la extracción de información de los textos de anuncios, aspecto clave para detectar dinámicas de gentrificación. (Fernández Ochoa, 2025)

Finalmente, el uso de herramientas de interpretación de modelos, como SHAP (*SHapley Additive exPlanations*), resulta clave porque permite entender qué factores influyen en la variación de los precios. Esto aporta mayor transparencia y genera confianza en los resultados, tanto para responsables públicos como para investigadores. (Martín Agüero, 2025)

En síntesis, la ciencia de datos aplicada al mercado inmobiliario ofrece un marco analítico que combina precisión técnica y valor interpretativo. A partir de este marco conceptual, el siguiente capítulo define los objetivos del proyecto y establece la orientación metodológica del estudio.

3. Objetivos

El presente trabajo tiene como finalidad analizar, mediante técnicas de ciencia de datos, las dinámicas del mercado inmobiliario en Madrid y su relación con los fenómenos de accesibilidad y gentrificación. Los objetivos se estructuran en dos niveles: generales y específicos.

3.1. Objetivos Generales:

- Analizar las dinámicas del mercado inmobiliario en Madrid con base en datos reales procedentes de portales inmobiliarios y fuentes oficiales.
- Desarrollar un Índice de Accesibilidad a la Vivienda (IAV) con base en evidencia que permita medir y comparar las desigualdades territoriales en el acceso a la vivienda en los distritos de Madrid.
- Detectar y caracterizar patrones asociados a la gentrificación mediante técnicas de aprendizaje no supervisado y análisis espacial, identificando áreas de transformación socioeconómica.

3.2. Objetivos Específicos:

- Reunir y depurar bases de datos de precios, características de viviendas, ubicación y tipología.
- Integrar variables socioeconómicas de fuentes públicas (INE, Ayuntamiento de Madrid).
- Desarrollar un modelo predictivo de precios de venta y alquiler de vivienda utilizando algoritmos de aprendizaje supervisado, evaluando su desempeño y capacidad de generalización temporal.
- Diseñar un IAV incorporando las dimensiones de renta, superficie mínima y coste por metro cuadrado en las modalidades de compra y alquiler.
- Implementar un modelo exploratorio de gentrificación basado en embeddings y clustering para identificar tipologías residenciales y patrones de revalorización urbana.

En conjunto, estos objetivos buscan establecer un marco analítico replicable, que combine la predicción de precios, la evaluación de accesibilidad y la detección temprana de procesos de gentrificación, aportando una base empírica sólida para la planificación urbana en la Comunidad de Madrid.

4. Metodología

4.1. Recolección e Integración de datos

El proyecto se sustenta en la integración de múltiples fuentes de información, combinando datos de mercado en tiempo real con indicadores oficiales y socioeconómicos. Este enfoque permite analizar de manera integral las dinámicas de precios y las desigualdades territoriales en el acceso a la vivienda en Madrid.

La arquitectura de datos presentada constituye un avance metodológico significativo en el estudio del mercado de vivienda en Madrid. La combinación de series temporales extensas, microdatos actuales y variables contextuales multisectoriales permite abordar con rigor las tres dimensiones clave del proyecto:

- **Predicción de precios:** modelos econométricos alimentados por variables explicativas estructurales y de mercado.
- **Evaluación de accesibilidad:** ratios de esfuerzo inmobiliario calculados a partir de renta disponible y precios efectivos.
- **Detección de gentrificación:** análisis longitudinal de cambios demográficos, de renta y de precios por distrito.

Este enfoque proporciona una base empírica sólida para informar políticas públicas de vivienda, planificación urbana y cohesión territorial en Madrid.

4.1.1. Fuentes de datos

El análisis se sustenta en la integración de **tres tipos de fuentes complementarias**, que combinan información de mercado en tiempo real con indicadores oficiales y territoriales. Esta integración garantiza la coherencia metodológica del estudio y la comparabilidad entre dimensiones económicas, demográficas y urbanas.

Estrategia de integración de datos

La Tabla 2 sintetiza la estructura de las fuentes empleadas y su función dentro del sistema de datos. El *web scraping* de Idealista proporciona la base empírica de precios y características de viviendas, mientras que los datos del INE y del Ayuntamiento de Madrid aportan el contexto socioeconómico y territorial necesario para vincular los resultados con las condiciones reales del entorno urbano.

Tabla 2. Orígenes de datos.

Datos de mercado	Datos oficiales del INE	Datos oficiales del Ayuntamiento de Madrid
•Web scraping de Idealista (septiembre 2025). •Microdatos actualizados sobre precios. •Características y ubicación de viviendas. •Operaciones de venta y alquiler.	•Información sobre renta y población. •Estructura demográfica. •Esperanza de vida.	•Variables urbanísticas y territoriales. •Indicadores de calidad de vida. •Densidad poblacional. •Zonas verdes. •Apartamentos turísticos.

Indicadores socioeconómicos clave

A partir de las fuentes oficiales se incorporaron indicadores representativos de la situación económica y demográfica de los distritos madrileños. Estos indicadores constituyen la base para evaluar la relación entre precios, renta y estructura poblacional, proporcionando un marco comparativo sólido para el cálculo del IAV.

Variables territoriales y urbanísticas

Además de los datos económicos y demográficos, se integraron variables urbanas que reflejan la configuración espacial y ambiental de la ciudad.

Factores como la densidad, la disponibilidad de zonas verdes o la concentración de apartamentos turísticos actúan como proxis de la calidad de vida, el atractivo residencial y la presión sobre el suelo urbano.

Ventajas de la estrategia metodológica

El sistema de integración adoptado se caracteriza por su granularidad espacial y temporal, su cobertura multidimensional y la validación cruzada de fuentes, lo que asegura la consistencia entre los datos de mercado y las estadísticas oficiales.

Además, su diseño modular permite la replicabilidad y escalabilidad, facilitando la actualización continua del modelo con nuevas observaciones o territorios.

Datos detallados de idealista: microdatos de mercado

Por último, se detallan los archivos extraídos del portal Idealista, que constituyen la base empírica del análisis.

Estos microdatos, obtenidos mediante web scraping en septiembre de 2025, recogen información detallada sobre precios, tamaño, localización, tipología y descripciones textuales de los anuncios de venta y alquiler.

La combinación de estas fuentes permite vincular la dinámica de precios con las condiciones socioeconómicas y demográficas del territorio, consolidando un sistema de información replicable y actualizado.

La combinación de estas fuentes permite vincular la dinámica de precios observada en el mercado con las condiciones socioeconómicas y demográficas del territorio.

Los principales archivos empleados fueron:

- **venta_vivienda.csv**: evolución del precio de venta medio de la vivienda (€/m²), por distrito y por meses, de 2006 a 2024 (Ayuntamiento de Madrid, 2025).
- **alquiler_vivienda.csv**: evolución del precio de alquiler medio de la vivienda (€/m²·mes), por distrito y por meses, de 2006 a 2024 (Ayuntamiento de Madrid, 2025).
- **renta_media_hogar.csv**: renta media, bruta y neta, por persona y por hogar, por distrito y año, de 2015 a 2022 (Ayuntamiento de Madrid, 2025).
- **esperanza_vida.csv**: esperanza de vida al nacer (años) por distrito y por año, de 2004 a 2024 (Ayuntamiento de Madrid, 2025).
- **datos_demograficos_ine.csv**: edad media, porcentaje de población menor de 18 años, porcentaje de población igual o mayor a 65 años, tamaño medio del hogar (personas) y población total, por distrito y año, de 2015 a 2022 (Instituto Nacional de Estadística (INE), 2025).
- **paro_registrado_2012_2024.csv**: paro absoluto registrado por distrito y mes, de diciembre de 2012 a diciembre de 2024 (Ayuntamiento de Madrid, 2025).
- **apartamentos_turisticos_2015_2022.csv**: cantidad de apartamentos turísticos por distrito y año, de 2015 a 2022 (Ayuntamiento de Madrid, 2025; Ayuntamiento de Madrid, 2016).
- **superficie_distrito.csv**: superficie en hectáreas de cada distrito, en 2021 (Ayuntamiento de Madrid, 2021).
- **superficie_zonas_verdes.csv**: superficie en hectáreas de zonas verdes y parques por distrito, año 2017 (Ayuntamiento de Madrid, 2025).
- **properties_all_alquiler-viviendas_pags_1-20.csv**: datos de alquiler de vivienda obtenidos de Idealista, que incluyen precio de alquiler (€/mes), ubicación, tamaño (m²), número de habitaciones, distrito, link y descripciones, año 2025 (Idealista, 2025).
- **properties_all_venta-viviendas_pags_1-20.csv**: datos de venta de vivienda obtenidos de Idealista, que incluyen precio de venta (€), ubicación, tamaño (m²), número de habitaciones, distrito, link y descripciones, año 2025 (Idealista, 2025).

4.1.2. Extracción automatizada de datos desde Idealista

Para la recopilación de microdatos inmobiliarios se desarrolló un script en Python que automatiza la extracción de anuncios desde Idealista, con el objetivo de obtener un conjunto homogéneo y replicable de datos.

El proceso incluyó:

- Navegación automatizada por páginas de resultados de cada distrito.
- Registro de variables clave (precio, superficie, número de habitaciones, tipo de vivienda, dirección abreviada, descripción y enlace).
- Parámetros configurables para definir distrito, rango de páginas y tipo de operación (venta/alquiler).
- Modos de ejecución:
 - Modo estándar, que realiza pausas aleatorias y movimientos en la web.
 - Modo *stealth*, que imita mejor el comportamiento humano y aplica mayor robustez para evitar bloqueos.
 - Modo rápido, que acelera el proceso reduciendo tiempos de espera, con el consecuente aumento de riesgo de bloqueo.
- Mecanismos de robustez: almacenamiento en caché local, esperas aleatorias, reintentos automáticos y control de errores.

Los resultados se almacenaron en ficheros CSV normalizados, tanto por distrito como en un consolidado general, listos para su integración con fuentes oficiales.

El *scraping* se realizó con fines exclusivamente académicos, respetando las condiciones de uso del portal y garantizando que los datos fueran analizados únicamente de forma agregada y anónima.

En la Figura 2 se muestra un diagrama de flujo que muestra el comportamiento general del software de *web scraping* desarrollado en Python.




Figura 2. Diagrama de flujo del programa de web scraping.

4.1.3. Unificación y enriquecimiento de los anuncios

Tras la recopilación, se unificaron y depuraron los ficheros de venta y alquiler. Se eliminaron duplicados, se normalizaron formatos y se corrigieron errores en la variable de superficie.

Posteriormente, se realizó un proceso de ingeniería de variables a partir de los textos descriptivos de los anuncios. Mediante expresiones regulares y búsqueda de patrones lingüísticos se extrajo información implícita no disponible en formato estructurado, como:

- Presencia de equipamientos (garaje, trastero, piscina, terraza o balcón).
- Características del edificio (planta, orientación, ascensor).
- Antigüedad y reformas (menciones a año de construcción o rehabilitación).
- Tipología de vivienda (piso, ático, dúplex, chalet, loft, etc.).
- Número de baños.

Este procedimiento transformó descripciones textuales en variables cuantificables, enriqueciendo la base de datos. Validaciones manuales sobre muestras representativas confirmaron un nivel de precisión superior al 90 % en la mayoría de las variables.

El resultado fue un fichero consolidado (*inmuebles_unificado_total_final.csv*) que integra información estructurada y semiestructurada, preservando la trazabilidad del proceso.

4.1.4. Integración con fuentes oficiales

Con los datos de Idealista ya depurados y enriquecidos, el siguiente paso fue integrarlos con las series oficiales del INE y del Ayuntamiento, construyendo un panel maestro a nivel distrito y año.

El procedimiento incluyó la normalización de formatos numéricos y temporales, la estandarización de los nombres de distrito y la agregación de indicadores a escala anual. De este modo, se incorporaron progresivamente variables de esperanza de vida, renta media por persona y hogar (neta y bruta), estructura demográfica, tasas de paro registrado, número de apartamentos turísticos y densidades poblacionales y de zonas verdes.

Todas las uniones se realizaron mediante claves consistentes (Distrito y Año), asegurando que no se perdiera información de los anuncios inmobiliarios y anotando valores faltantes cuando no existían datos oficiales para determinados años o distritos.

El resultado fue un conjunto de datos consolidado (*gentrificacion_madrid.csv*), que recoge tanto los precios de mercado como los principales indicadores socioeconómicos y urbanísticos de Madrid.

4.1.5. Proyección retrospectiva de precios

Una vez consolidada la base de datos —que integraba los anuncios inmobiliarios de Idealista con las fuentes oficiales del Ayuntamiento de Madrid y del INE—, se procedió a asignar a cada inmueble una trayectoria histórica coherente con la evolución de precios observada en su distrito. El objetivo de esta fase fue construir un panel temporal completo (2011–2024) que sirviera de base para el análisis exploratorio y el posterior modelado predictivo.

Para ello se aplicó un método de proyección proporcional fundamentado en la hipótesis de estabilidad relativa intra distrital. Este supuesto plantea que la posición de un inmueble respecto al precio medio de su distrito se mantiene constante a lo largo del tiempo. En consecuencia, el precio observado en el año de referencia se ajusta hacia los años anteriores en función de la variación interanual del precio medio distrital.

El procedimiento se expresa mediante la ecuación:

$$P_{i,t} = P_{i,t_0}^{obs} \times \frac{\bar{P}_{d,t}}{\bar{P}_{d,t_0}}$$

donde P_{i,t_0}^{obs} es el precio observado del inmueble i en el año de referencia t_0 ; y $\bar{P}_{d,t}$ y $\bar{P}_{d,t_0}$ son los precios medios del distrito d en los años t y t_0 , respectivamente. Dicho de otra forma, se trata de una regla de tres que relaciona proporcionalmente el valor de las viviendas con el precio medio de cada distrito en cada año.

La implementación se realizó mediante una función en Python (*calcular_alquiler_venta*), aplicada de manera independiente a los mercados de venta y alquiler, lo que permitió reconstruir automáticamente las series anuales de más de 25.000 viviendas.

4.1.5.1. Métodos de ajuste

Debido a que el procedimiento de predicción de precios pasados se basa en una relación proporcional a la media, se decidió realizar un ligero ajuste en los precios. Para ello, se creó una función en Python (*aplicar_ruido_precios*) para incluir ruido entre 0% y 5% del precio original, en una distribución normal o gaussiana.

La fórmula matemática detrás de este ajuste podría definirse de la siguiente manera:

$$P_i^{(aj)} = \hat{P}_i + \varepsilon_i$$

donde:

$$\varepsilon_i \sim N(0, \sigma_i^2)$$

y donde:

$$\sigma_i = |\hat{P}_i| \cdot f$$

Siendo $\hat{P}_i$ cada precio predicho; f el factor de ruido (0,05); σ_i la desviación estándar de cada precio predicho; ε_i el ruido aleatorio obtenido de la distribución normal; y $P_i^{(aj)}$ el valor predicho ajustado.

4.1.5.2. Validación visual del método

Las figuras 3 a 6 muestran la evolución de los precios proyectados por distrito tras la aplicación del ajuste híbrido. El objetivo de esta validación fue comprobar la coherencia temporal y espacial del método de proyección proporcional y confirmar la estabilidad de las series distritales generadas.




Figura 3. Evolución del precio de venta medio proyectado por distrito y año.




Figura 4. Evolución del precio de alquiler medio proyectado por distrito y año.

El análisis comparativo entre las series proyectadas muestra que el método reproduce correctamente la tendencia global del mercado madrileño. No obstante, se detectan sesgos sistemáticos de sobreestimación en los distritos con precios medios más elevados —especialmente Moncloa-Aravaca, Hortaleza y Chamartín—, donde las proyecciones tienden a amplificar las subidas observadas en los años más recientes

En contraste, distritos con valores medios o bajos, como Latina o Carabanchel, presentan una correspondencia más estable y coherente con las dinámicas históricas del mercado, reflejando un comportamiento más homogéneo.

Este patrón evidencia que, aunque el método proporcional capta adecuadamente las tendencias generales, tiende a exagerar las desviaciones en contextos de valores extremos o con menor densidad de observaciones. Por ello se consideró necesario incorporar ajustes complementarios que suavicen las sobrerreacciones en los distritos con mayor volatilidad.




Figura 5. Comparación de precios de venta reales y proyectados por distrito después del ajuste (2011-2024).




Figura 6. Comparación de precios de alquiler reales y proyectados por distrito después del ajuste (2011-2024).

Tras aplicar el modelo híbrido de ajuste —que combina factores de corrección y límites de desviación, junto con ruido gaussiano controlado—, las curvas de precios proyectados se alinearon con mayor precisión a los valores reales. La mejora se refleja especialmente en los distritos de Salamanca, Chamartín y Moncloa-Aravaca, donde se redujeron las desviaciones máximas y se suavizaron los picos extremos.

En conjunto, los resultados muestran una mayor estabilidad intra distrital y coherencia temporal, garantizando una representación más realista de la evolución de los precios tanto en venta como en alquiler.

Durante la validación se identificó una fuente puntual de error asociada a anuncios duplicados de viviendas de alto valor (superiores a 3 millones de euros), generalmente publicados por múltiples agencias. Esto se debe a que las viviendas de lujo tienden a contratar varias empresas inmobiliarias,

y estas publican anuncios independientes en la web, lo cual hace que se repitan datos que corresponden a las mismas viviendas.

Para corregir este desajuste, debido a la falta de variables que permitiesen identificar las viviendas repetidas, se aplicó un filtro por coincidencia de precios, ya que las viviendas de lujo son relativamente escasas y es poco común que se repita exactamente el mismo precio en dos viviendas diferentes. Aunque el impacto residual de estos casos fue mínimo debido a su baja proporción sobre el total de registros, la exclusión de valores extremos repetidos contribuyó a mejorar la calidad y consistencia general del modelo.

La validación visual del método confirma que el ajuste híbrido logra un equilibrio adecuado entre precisión y estabilidad, evitando tanto la rigidez de los límites estrictos como la sobre-reacción del ajuste simple.

El procedimiento resultó en la generación del archivo *viviendas_2011_2024.csv*, que almacena para cada inmueble una serie temporal ajustada de precios estimados, junto con las variables socioeconómicas y urbanísticas de su distrito.

Este panel constituye la base de trabajo del análisis exploratorio (EDA) y de los modelos predictivos presentados en las secciones posteriores, garantizando una estructura temporal coherente y comparable en todo el periodo analizado.

4.2. Análisis exploratorio de datos (EDA)

El análisis exploratorio se aplicó al panel consolidado de viviendas correspondiente al periodo 2011-2024. El objetivo de esta fase fue comprender la estructura de los datos, detectar valores atípicos y patrones de comportamiento, así como establecer los fundamentos descriptivos que orientan el posterior modelado predictivo de precios.

4.2.1. Preparación y calidad de los datos

En primer lugar, se realizó una revisión de la completitud y consistencia del conjunto de datos. Se calcularon los porcentajes de valores faltantes por variable y se analizaron las principales estadísticas descriptivas (media, mediana, desviación estándar, cuartiles). El análisis se realizó de forma diferenciada para las operaciones de venta y alquiler, con el fin de evitar distorsiones derivadas de mezclar mercados con dinámicas distintas.

La detección de valores atípicos se abordó mediante el método del rango intercuartílico (IQR), aplicando los umbrales $Q1 - 1.5 \times IQR$ y $Q3 + 1.5 \times IQR$ a la variable de precio. Este

procedimiento permitió identificar registros con precios extremadamente altos o bajos, manteniendo la representatividad del conjunto principal.

Las figuras 7 y 8 muestran la distribución de precios diferenciando las operaciones de venta y alquiler, con y sin valores atípicos, donde se aprecia una asimetría positiva y la presencia de valores extremos propios de un mercado inmobiliario heterogéneo. Este comportamiento evidencia la necesidad de emplear medidas de tendencia central robustas, como la mediana, para representar de forma más fiel el valor típico de los inmuebles en cada segmento.




Figura 7. Boxplot de precios por operación. (Izquierda: venta; derecha: alquiler).




Figura 8.Boxplot de precios, sin valores atípicos, por operación. (Izquierda: venta; derecha: alquiler).

El proceso de depuración garantizó la consistencia y validez estadística del conjunto de datos, manteniendo más del 90 % de los registros originales y eliminando únicamente valores extremos que podrían distorsionar el modelado posterior.

De forma complementaria, el conjunto inicial comprendió 209.216 registros y 32 variables. Las variables con mayor proporción de nulos fueron el año de reforma (99,6 %) y el año de construcción (97,8 %), que se excluyeron por su baja completitud. En el bloque socioeconómico (rentas, edad

media o paro registrado, entre otras) se identificaron alrededor de 89.000 valores faltantes ($\approx 43\%$), pero se encontró que los datos se encontraban completos entre los años 2015 y 2022, ambos inclusive, por lo que se decidió utilizar dicho rango temporal para el posterior modelado.

La variable Planta contenía menos del 10% de nulos, por lo que imputó por la mediana. Se constató una distribución desigual por distrito, con mayor número de registros en Chamartín, Centro y Tetuán; y menor en Barajas, Vicálvaro y Moratalaz.

El filtrado de valores atípicos mediante el método IQR permitió localizar 9.083 registros en venta (7,6 %) y 5.710 en alquiler (7,1 %), garantizando la consistencia y estabilidad estadística del conjunto final.

4.2.2. Distribuciones univariantes

Una vez depurados los valores atípicos, se examinaron las distribuciones de precios ajustados según variables clave como tipo de operación, distrito y tipología de vivienda.




Figura 9. Distribución del precio de venta en Madrid (2011-2024).




Figura 10. Distribución del precio de alquiler en Madrid (2011-2024).

Ambos gráficos muestran una fuerte asimetría positiva, con predominio de inmuebles en rangos de precios bajos y pocos valores muy altos. Este comportamiento confirma la heterogeneidad del mercado madrileño, donde conviven propiedades asequibles con viviendas premium concentradas en zonas centrales. En venta, los precios se concentran entre 150.000 y 500.000 €, mientras que en alquiler oscilan entre 800 y 1.600 €/mes.




Figura 11. Distribución del precio por tipo de vivienda en Madrid (2011-2024).

Los apartamentos constituyen el tipo predominante ($\approx 87\%$ en venta y 90% en alquiler), seguidos de áticos, chalets y dúplex. Las tipologías exclusivas (lofts, triplex o mansiones) presentan baja frecuencia, pero precios significativamente diferentes.

Este patrón refuerza que el mercado madrileño está dominado por vivienda en bloque multifamiliar, un aspecto relevante para interpretar la segmentación espacial posterior.

4.2.3. Análisis por distrito

Con el fin de caracterizar las diferencias territoriales, se calcularon los valores medios de precio por distrito, que se muestran en las Figuras 12 y 13.




Figura 12. Boxplot de precio medio de venta por distrito, entre 2011 y 2024.




Figura 13. Boxplot de precio medio de alquiler por distrito, entre 2011 y 2024.

En la modalidad de venta, los distritos del norte y este presentan valores de precio significativamente mayores respecto a la zona sur y suroeste, así como una mayor dispersión. A su vez, en la modalidad de alquiler, estas diferencias no son tan significativas, pero sigue existiendo mayor valor y dispersión en la zona norte.




Figura 14. Precios medianos de venta por metro cuadrado por distrito (2011-2024).




Figura 15. Precios medianos de alquiler por metro cuadrado por distrito (2011-2024).

En el caso de los precios medianos de venta (Figura 14), los distritos que muestran mayores valores son Salamanca, Chamberí y Chamartín; y los que muestran menores, Villaverde, Puente de Vallecas y Usera. En los precios medianos de alquiler (Figura 15), se observa una distribución similar, siendo los más altos en precio Centro, Salamanca y Chamberí; y los más bajos, Villaverde, Vicálvaro y Villa de Vallecas. Aunque la distribución varía, se puede entender claramente que existe una gran diferencia entre los distritos de centro y norte de la ciudad respecto a los del sur, en ambos casos.




Figura 16. Tamaño medio de vivienda por distrito en Madrid (2011–2024).

Respecto al tamaño de las viviendas (figura 16), los distritos de Moncloa-Aravaca, Hortaleza y Chamartín presentan las viviendas más amplias (superiores a 140 m²); mientras que Arganzuela, Puente de Vallecas y Villaverde se sitúan en el rango inferior (75-90 m²). En el caso de Moncloa-Aravaca, su diferencia significativa con el resto de los distritos puede explicarse fácilmente por dos características propias: por una parte, es el distrito con más mansiones (por la zona de Aravaca), que son de gran tamaño; y por otra parte, contiene una gran cantidad de viviendas destinadas a estudiantes (por la zona de Moncloa), que suelen ser grandes y con muchas habitaciones. Este gradiente norte-sur, ampliamente documentado en estudios de desigualdad urbana, confirma una segmentación territorial clara del mercado madrileño y constituye la base empírica sobre la que se construye el Índice de Accesibilidad a la Vivienda (IAV) en el siguiente capítulo.

4.2.4. Correlaciones

Para identificar relaciones entre variables cuantitativas se calcularon los coeficientes de Pearson (lineales) y Spearman (monótonos).




Figura 17. Correlación de Pearson.




Figura 18. Correlación de Spearman

Las correlaciones (Figuras 17 y 18) muestran alta colinealidad entre los indicadores de renta (superiores a 0,95), lo que justifica la selección de un único indicador representativo para el modelado. Asimismo, se observa una relación inversa entre desempleo y renta, evidenciando la segregación socioeconómica por distritos. En el ámbito inmobiliario, el tamaño de la vivienda (m²) presenta una correlación moderada y positiva con el precio ($\approx 0,5$), mientras que el precio por m² tiende a disminuir conforme aumenta la superficie. Estas relaciones sirvieron de base para optimizar la selección de variables predictoras, priorizando aquellas de mayor independencia.

En cuestión a las variables dicotómicas, se realizó un modelo simple de regresión lineal para analizar la relación entre estas y la variable objetivo (precio). Con este análisis, se encontró que las variables de Trastero y Terraza no tenían una relación lineal significativa ($p > 0.05$). Las demás variables obtuvieron un $p < 0.05$, pero con poca relación real en base a las demás métricas.

4.2.5. Evolución temporal (2011-2024)

Se analizó la evolución anual de la mediana del precio ajustado, diferenciando operaciones de venta y alquiler a partir de las series proyectadas validadas anteriormente. Esta evolución se puede visualizar en las figuras 19 y 20.




Figura 19. Evolución anual del precio mediano en venta (2011-2024).




Figura 20. Evolución anual del precio mediano en alquiler (2011-2024).

Entre 2011 y 2014 se observa una fase de contracción vinculada a la crisis financiera del 2008, con mínimos en 2014 (211.970 € en venta y 861 € en alquiler). Desde 2015, ambos mercados muestran una recuperación sostenida, alcanzando máximos históricos en 2024 (353.572 € en venta y 1.458 € en alquiler).

El estancamiento en los precios de venta y disminución en los de alquiler se asocian a la crisis derivada de la pandemia de COVID-19 de 2020, que rápidamente se recuperaron a partir de 2022.

Estas tendencias confirman la revalorización estructural del mercado inmobiliario madrileño y justifican la inclusión de la variable temporal en los modelos predictivos.

Complementariamente, se examinó el contenido semántico de los anuncios mediante una nube de palabras generada a partir de las descripciones (figura 21).

4.3. Análisis del mercado y modelado predictivo

4.3.1. Modelos predictivos

A partir de los patrones identificados en el análisis exploratorio (EDA), se desarrollaron modelos de aprendizaje automático supervisado de predicción de variable continua en estructura tabular con datos estructurados, para obtener los precios de venta y alquiler futuros de las viviendas en Madrid.

Se compararon distintos algoritmos de aprendizaje automático en un entorno reproducible, priorizando la robustez temporal, la interpretabilidad y la capacidad de generalización. El objetivo fue evaluar la capacidad de distintos algoritmos para capturar la complejidad estructural, espacial y temporal del mercado inmobiliario.

La estrategia metodológica se basó en la construcción de pipelines reproducibles, la validación temporal y la optimización de parámetros, garantizando que las predicciones no se vieran afectadas por fuga de información entre periodos.

4.3.1.1. Preparación del dataset y codificación de variables

Antes del entrenamiento de los modelos se aplicó un proceso de preprocesamiento estructurado, que incluyó:

- Filtrado temporal (años 2015-2024) para mantener una base homogénea.
- Eliminación de variables con alta proporción de valores nulos (año de construcción y año de reforma).
- Imputación de valores faltantes en Planta mediante la mediana distrital y creación de una variable indicadora (*Planta_is_missing*).
- Imputación de variables socioeconómicas faltantes en años 2023 y 2024 mediante un modelo simple de regresión lineal.
- Codificación con *dummies* para las variables categóricas y ordenamiento cronológico del dataset.
- División entre operaciones de venta y de alquiler.

El conjunto final quedó conformado por 149.440 observaciones y 57 variables predictoras, integrando atributos físicos, tipológicos y contextuales de los inmuebles. Para el conjunto de venta, se obtuvieron 73.504 observaciones en entrenamiento y 18.376 en prueba; y para el conjunto de alquiler, se obtuvieron 46.048 observaciones en entrenamiento y 11.512 en prueba.

4.3.1.2. División temporal de los datos

Debido al carácter secuencial del mercado, se empleó una validación temporal que preserva el orden cronológico de las observaciones, evitando el uso de información futura en la fase de validación. Se realizaron *splits* temporales para hacer entrenamiento y validación por fases de forma cronológica.

Tabla 3. División temporal de los datos

CONJUNTO	PERIODO	PROPÓSITO
ENTRENAMIENTO Y VALIDACIÓN	2015-2022	Ajuste de parámetros del modelo
PRUEBA FINAL	2023-2024	Evaluación de generalización interanual

Esta estrategia permite evaluar la capacidad de generalización temporal de los modelos frente a los cambios estructurales del mercado.

4.3.1.3. Pipeline de modelado

Se construyó un pipeline reproducible con dos componentes principales:

- Escalado robusto de variables numéricas, mediante *RobustScaler*, que reduce el impacto de los valores atípicos (*outliers*). Este paso se utilizó únicamente para modelos sensibles, concretamente modelos lineales, basados en distancias y de redes neuronales.
- Modelo de regresión supervisada, ajustado según el algoritmo seleccionado.

El uso de pipelines permitió mantener un flujo de trabajo limpio y replicable, facilitando la comparación entre modelos y su posterior integración en el proceso de optimización.

4.3.1.4. Selección de modelos base

Con el objetivo de identificar el modelo más robusto y equilibrado, se compararon cinco algoritmos representativos:

- **Ridge Regression (Regresión Ridge):** modelo lineal regularizado mediante penalización L2 para reducir la varianza y evitar sobreajuste.
- **K-Nearest Neighbors (KNN):** modelo no paramétrico basado en distancias; predice en función de los valores de los k vecinos más cercanos.
- **Multi-Layer Perceptron Regressor (MLPRegressor):** red neuronal artificial de tipo *feedforward* con varias capas ocultas; captura relaciones no lineales.
- **HistGradientBoosting Regressor (HGB):** algoritmo de *gradient boosting* basado en histogramas, eficiente para grandes volúmenes de datos numéricos.
- **Light Gradient Boosting Machine (LightGBM):** implementación optimizada de *gradient boosting* que usa histogramas y crecimiento basado en hojas (*leaf-wise*) para mayor velocidad y rendimiento.

Se decidió elegir modelos más tradicionales y simples para usar de base comparativa con modelos más avanzados. En cuanto a los avanzados, se eligieron preferiblemente modelos de gradiente frente árboles de decisión o *random forest* debido a su buen desempeño y al menor coste computacional por ser más nuevos y eficientes. Por último, se escogió también una red neuronal multicapa para comparar el desempeño con aprendizaje profundo.

La validación cruzada temporal se aplicó mediante *TimeSeriesSplit* con cinco divisiones consecutivas. Los resultados se resumen en las tablas 4 y 5, donde se observa que el modelo LGBM obtuvo los mejores resultados generales.

Tabla 4. Resultados de validación cruzada de modelo de venta (2015-2022).

MODELO	CONJUNTO	MAE (EUR)	RMSE (EUR)	R ²	MAPE (%)
LIGHT GBM (LGBM)	Validación	16.107,63	33.855,91	0,9959	3,88
	Entrenamiento	7.937,94	14.287,63	0,9990	-
HISTGRADIENTBOOSTING (HGB)	Validación	19.589,23	104.686,64	0,9717	2,92
	Entrenamiento	13.616,54	76.919,24	0,9767	-
MULTI-LAYER PERCEPTRON (MLP)	Validación	38.147,52	71.809,93	0,9816	9,29
	Entrenamiento	37.989,26	83.757,19	0,9716	-
K-NEAREST NEIGHBORS (KNN)	Validación	48.581,07	87.540,60	0,9770	10,14
	Entrenamiento	0,01	0,08	1,0000	-
RIDGE REGRESSION	Validación	96.629,83	155.845,68	0,9187	27,92
	Entrenamiento	89.930,24	160.373,08	0,8979	-

Tabla 5. Resultados de validación cruzada de modelo de alquiler (2015-2022).

MODELO	CONJUNTO	MAE (EUR)	RMSE (EUR)	R ²	MAPE (%)
LIGHT GBM (LGBM)	Validación	30,28	62,60	0,9969	1,93
	Entrenamiento	15,95	28,28	0,9992	-
HISTGRADIENTBOOSTING (HGB)	Validación	35,86	108,52	0,9906	1,89
	Entrenamiento	30,53	119,21	0,9877	-
MULTI-LAYER PERCEPTRON (MLP)	Validación	77,35	140,58	0,9843	5,66
	Entrenamiento	79,59	165,01	0,9768	-
K-NEAREST NEIGHBORS (KNN)	Validación	123,13	189,96	0,9713	8,61
	Entrenamiento	0,00	0,00	1,0000	-
RIDGE REGRESSION	Validación	316,08	530,28	0,7945	21,83
	Entrenamiento	240,74	408,19	0,7996	-

4.3.1.5. Optimización de parámetros

Tras realizar validación cruzada temporal mediante *TimeSeriesSplit* para comparar los distintos algoritmos candidatos, se identificó al LGBM como el modelo más prometedor para ambos casos. A continuación, se procedió a optimizar sus parámetros mediante Optuna, maximizando la precisión en validación temporal (minimización del MAE).

Los mejores conjuntos de parámetros de cada modelo fueron los siguientes:

Tabla 6. Mejores parámetros para modelos predictivos de venta y alquiler.

Modelo de venta	Modelo de alquiler
•<i>n_estimators</i>: 900 •<i>learning_rate</i>: 0.04516323739970411 •<i>num_leaves</i>: 115 •<i>min_child_samples</i>: 5 •<i>subsample</i>: 0.9437472135000113 •<i>colsample_bytree</i>: 0.6342151999936305 •<i>reg_alpha</i>: 0.5259426090399767 •<i>reg_lambda</i>: 0.005782551092910595 •<i>min_split_gain</i>: 0.03949136140253775 •<i>feature_fraction_bynode</i>: 0.7375780469764728	•<i>n_estimators</i>: 1000 •<i>learning_rate</i>: 0.04900114778165227 •<i>num_leaves</i>: 217 •<i>min_child_samples</i>: 15 •<i>subsample</i>: 0.6162117911197653 •<i>colsample_bytree</i>: 0.9777827118271573 •<i>reg_alpha</i>: 4.681921649616876e-08 •<i>reg_lambda</i>: 1.779940897212616e-06 •<i>min_split_gain</i>: 0.2375372465694599 •<i>feature_fraction_bynode</i>: 0.8452611076023279

4.3.1.6. Entrenamiento final y evaluación

El modelo optimizado se entrenó con todos los datos históricos (2015-2022) y se evaluó en el conjunto de prueba (2024):

Tabla 7. Resultados de prueba de venta (2023-2024).

AÑO	MAE	RMSE	MAPE	R ²
2023	18.815,19	53.987,72	3,27	0,993
2024	33.310,86	96.462,53	4,65	0,982




Figura 22. Relación entre precios reales y predichos de venta (test 2023-2024).

Tabla 8. Resultados de prueba de alquiler (2023-2024).

AÑO	MAE	RMSE	MAPE	R ²
2023	46,89	135,42	2,07	0,99
2024	83,61	240,64	3,12	0,97




Figura 23. Relación entre precios reales y predichos de alquiler (test 2023-2024).

Observando las figuras 22 y 23, los puntos cercanos a la línea de predicción perfecta (en rojo) evidencian la alta precisión del modelo y la ausencia de sesgos significativos. Las desviaciones se concentran principalmente en el segmento de inmuebles de lujo, lo cual es esperable por su menor representatividad estadística.




Figura 24. Distribución del error relativo en venta por rango de precios.




Figura 25. Distribución del error relativo en alquiler por rango de precios.

Tal y como se muestra en la figura 24, el modelo de venta mantiene un error promedio inferior al 10 % en los tramos inferiores a 2.000.000 €, aumentando ligeramente en el segmento superior por la mayor heterogeneidad de viviendas. En la Figura 25, se observa un comportamiento similar para el modelo de alquiler, aunque con diferencias más significativas entre los rangos seleccionados, con los valores por encima de 2.000 € con un mayor porcentaje de error relativo. Este comportamiento confirma la consistencia del modelo en distintos niveles de precio, reforzando su utilidad para análisis territoriales de accesibilidad.




Figura 26. Importancia relativa de las variables en el modelo LGBM de venta.




Figura 27. Importancia relativa de las variables en el modelo LGBM de alquiler.

El análisis de importancia (Figura 26) muestra que las variables más influyentes en el modelo de venta son el ratio vs distrito (relación entre el precio del inmueble y el promedio distrital), el precio promedio del año anterior (que refleja la dimensión temporal del mercado) y el tamaño de la vivienda. Por su parte, en el modelo de alquiler (Figura 27), las variables más influyentes son el tamaño, la tendencia de precios del distrito y el ratio vs distrito.

Estas variables confirman que los modelos no solo capturan las características físicas del inmueble, sino también las dinámicas socioeconómicas y contextuales, lo que garantiza coherencia con los objetivos del estudio.

El flujo completo —desde la preparación de datos hasta la evaluación final— permitió consolidar un proceso de predicción robusto y reproducible. El modelo LGBM optimizado ofreció el mejor equilibrio entre precisión, estabilidad temporal e interpretabilidad, convirtiéndose en la base para el IAV y la posterior exploración de patrones de gentrificación.

En conjunto, los resultados validan la capacidad del modelo para estimar precios ajustados con alta fiabilidad y sustentan su uso como componente central de la plataforma analítica desarrollada en este trabajo.

4.4. Diseño del Índice de Accesibilidad a la Vivienda (IAV)

El objetivo de este índice es cuantificar la capacidad económica de los hogares madrileños para acceder a una vivienda mínima, tanto en compra como en alquiler, y comparar las desigualdades territoriales de accesibilidad en el tiempo.

El IAV se construyó a partir de los precios estimados ajustados y de las rentas medias distritales obtenidas de fuentes oficiales (Ayuntamiento de Madrid e INE).

4.4.1. Enfoque conceptual

El IAV parte de la premisa de que la accesibilidad habitacional depende de la relación entre ingresos del hogar y coste de la vivienda. Siguiendo la literatura internacional, se definieron dos modalidades complementarias (World Bank & United Nations Centre for Human Settlements (UNCHS), 1993; Organisation for Economic Co-operation and Development (OECD), 2023):

- **IAV de compra:** mide la capacidad de los hogares para adquirir una vivienda mínima.
- **IAV de alquiler:** mide la capacidad para afrontar el arrendamiento de la vivienda.

Ambas versiones utilizan un enfoque comparable y se basan en tres componentes principales:

- **Precio de mercado (€/m²)** — estimado mediante los valores medios.
- **Superficie mínima de referencia (40-50 m²)** — según normativa urbanística del PGOUM. (Ayuntamiento de Madrid, 2023) En este caso, se considera que dicho tamaño es adecuado para una vivienda con 1 o 2 personas.
- **Renta disponible del hogar (€/año)** — procedente de datos del Ayuntamiento de Madrid. (Ayuntamiento de Madrid, 2025)

El índice resultante permite analizar diferencias territoriales y temporales en la accesibilidad, así como la brecha entre compra y alquiler, lo que contribuye a distinguir las desigualdades sociales y económicas en el acceso a la vivienda dentro del mercado madrileño.

Para garantizar la comparabilidad entre distritos, se adoptó una superficie mínima de 40 m² útiles, conforme al Plan General de Ordenación Urbana de Madrid. Esta superficie representa el estándar mínimo de habitabilidad, que debe incluir sala, cocina, dormitorio y baño. El uso de un valor fijo evita que las diferencias de tamaño medio por distrito distorsionen la comparación, asegurando que el IAV refleje solo la relación entre renta y precio, no entre tipos de vivienda. (Ayuntamiento de Madrid, 2023)

4.4.2. IAV de Compra (basado en precio de venta por metro cuadrado)

El IAV de Compra evalúa la capacidad de los hogares para asumir el coste de adquisición de una vivienda mínima.

$$IAV_{compra} = \frac{Renta\ media\ bruta\ del\ hogar \times 3}{Precio\ venta\ \left(\frac{\text{€}}{m^2}\right) \times A_{ref}}$$

donde:

$$A_{ref} = \begin{cases} S_{ref}, & \text{si Cantidad de personas} \leq 2 \\ \frac{S_{ref}}{2} \times \text{Cantidad de personas}, & \text{si Cantidad de personas} > 2 \end{cases}$$

y donde S_{ref} representa la superficie mínima normativa (40 m²).

La fórmula del índice considera en parte el nivel de esfuerzo para la adquisición de vivienda (indicado más adelante), que a nivel financiero indica que lo adecuado es comprar una vivienda cuyo valor de mercado sea como máximo 5 veces la renta bruta anual, preferiblemente 3 veces. A partir de esto, se utiliza el área de referencia para una vivienda mínima dependiendo del número de habitantes del hogar, que considera que 40 m² es el mínimo indispensable para una o dos personas, pero se adapta si existen más.

Finalmente, del IAV para compra se obtienen los siguientes rangos de evaluación:

- **IAV < 1:** la renta anual no alcanza para cubrir el coste de una vivienda mínima (inaccesibilidad).
- **IAV = 1:** los ingresos apenas alcanzan el valor mínimo de acceso (accesibilidad precaria).
- **IAV > 1:** la renta supera el coste estimado, indicando mayor accesibilidad.

Este indicador amplía la lógica del *Median Multiple*, al convertir el precio por m² en un coste total ajustado por superficie. De este modo, se obtiene una medida más homogénea y replicable que permite comparar el esfuerzo económico entre distritos y en diferentes periodos.

Este índice, no obstante, tiene dos limitaciones importantes: por una parte, no se están teniendo en cuenta los gastos anuales del hogar, que pueden variar entre un grupo familiar u otro; y por otra parte, no se tiene en cuenta el 20% del precio de la vivienda que generalmente se debe tener ahorrado para poder acceder a una hipoteca. Esta falta de datos hace que el valor del IAV resulte ligeramente más elevado respecto a la realidad.

De forma complementaria al IAV de Compra, se estimó el nivel de esfuerzo de compra, definido como la proporción entre el precio de la vivienda y la renta bruta anual del hogar. Este indicador mide el número de años necesarios para adquirir una vivienda si se destinase toda la renta bruta del hogar a ello, y permite comparar el grado de accesibilidad económica entre distritos. (Banco de España, 2024)

$$Esfuerzo_{compra} = \frac{\text{Precio de venta}}{\text{Renta bruta anual del hogar}}$$

Un mayor valor del esfuerzo de compra indica menor accesibilidad, es decir, un número más alto de años de renta necesarios para adquirir una vivienda.

De acuerdo con los estándares internacionales (UN-Habitat, 2024; World Bank & United Nations Centre for Human Settlements (UNCHS), 1993), se consideran las siguientes categorías:

- **Esfuerzo de compra ≤ 3 :** vivienda muy asequible.
- **$3 < \text{Esfuerzo de compra} \leq 5$:** accesibilidad moderada.
- **Esfuerzo de compra > 5 :** mercado gravemente inaccesible.

Este indicador complementa al IAV de compra, al expresar el esfuerzo real de adquisición en términos de años de ingreso requeridos, ofreciendo una medida más tangible de la presión económica sobre los hogares.

4.4.3. IAV de Alquiler (basado en precio de alquiler €/m²).

El IAV de Alquiler mide la capacidad de los hogares para cubrir el coste del arrendamiento anual de una vivienda mínima.

$$IAV_{alquiler} = \frac{\text{Renta media neta del hogar}}{\text{Precio alquiler} \left(\frac{\text{€}}{\text{m}^2 \cdot \text{mes}} \right) \times A_{ref} \times 12}$$

donde:

$$A_{ref} = \begin{cases} S_{ref}, & \text{si Cantidad de personas} \leq 2 \\ \frac{S_{ref}}{2} \times \text{Cantidad de personas}, & \text{si Cantidad de personas} > 2 \end{cases}$$

y donde S_{ref} representa la superficie mínima normativa (40 m²).

Igualmente, este índice también contiene una limitación: no se tienen en cuenta los gastos anuales del grupo familiar, por lo que existe la posibilidad de que factores externos agraven la accesibilidad real.

Del IAV de alquiler se obtienen los siguientes rangos de evaluación:

- **IAV ≥ 1 :** la renta es suficiente para cubrir el alquiler anual sin sobrecarga.
- **IAV < 1 :** el coste de arrendamiento supera la renta disponible (riesgo de sobreesfuerzo).

De forma complementaria, se estimó el nivel de esfuerzo de alquiler, definido como la proporción del ingreso destinada al pago del alquiler:

$$Esfuerzo_{alquiler} = \frac{Precio_{alquiler} \left(\frac{\text{€}}{m^2} \right) \times S_{ref} \times 12}{Renta_{media\ neta\ del\ hogar}}$$

Según los estándares de Eurostat y de OECD, un esfuerzo superior al 30–40 % indica sobrecarga de costes de vivienda. En el contexto español, el umbral del 33 % de la renta neta mensual se considera el límite de sostenibilidad financiera. (Eurostat, 2023; Organisation for Economic Co-operation and Development (OECD), 2023)

4.4.4. Marco de referencia internacional

El diseño del IAV se apoya en una tradición consolidada de indicadores internacionales:

- **Median Multiple** (UN-Habitat, 2024): relación entre precio medio de la vivienda y renta media del hogar.
- **Housing Affordability Index** (National Association of Realtors (NAR), 2022): compara ingresos familiares medios con los necesarios para acceder a una hipoteca.
- **Demographia International Housing Affordability Survey** (Cox & Pavletich, Demographia International Housing Affordability Survey: 2025 Edition, 2025): clasificación de mercados según accesibilidad (≤ 3 asequible; ≥ 5 , gravemente inaccesible).

El IAV adapta estos enfoques al contexto madrileño, introduciendo dos innovaciones:

- Distinción entre modalidades de compra y alquiler.
- Incorporación de una superficie normativa homogénea (a partir de 40 m²).

Estas mejoras permiten que el índice sea extrapolable a otros contextos urbanos, siempre que se ajusten las variables estructurales a la realidad local. De este modo, el IAV mantiene una estructura

metodológica coherente con los estándares internacionales, pero conserva la flexibilidad necesaria para adaptarse a diferentes escalas territoriales y sistemas de vivienda.

4.4.5. Nivel de esfuerzo y sostenibilidad financiera

El nivel de esfuerzo de adquisición o arrendamiento representa el porcentaje de la renta familiar destinado al pago de la vivienda. Se considera sostenible un esfuerzo inferior al 30–35 % de los ingresos mensuales. Superar este umbral implica vulnerabilidad económica o riesgo de sobreendeudamiento.

La combinación del IAV y del esfuerzo de renta ofrece una visión integral de la accesibilidad habitacional: el IAV mide la capacidad teórica de acceso, mientras que el esfuerzo refleja la sostenibilidad financiera real. Por ejemplo, un valor de IAV igual a 0,5 indica que la renta anual del hogar solo cubre la mitad del coste estimado de una vivienda tipo, lo que evidencia una situación de inaccesibilidad estructural. En cambio, un valor igual o superior a 1 sugiere que los ingresos del hogar son suficientes para afrontar el coste de una vivienda mínima sin sobrecarga económica.

Juntos, ambos indicadores permiten identificar distritos con desequilibrios estructurales y orientar el análisis territorial de accesibilidad que se desarrolla en el capítulo de resultados.

En síntesis, el IAV constituye una herramienta analítica transparente y adaptable, que combina precios de mercado, rentas y condiciones normativas para ofrecer una medida cuantitativa de la accesibilidad. Su diseño, alineado con estándares internacionales, permite detectar desigualdades estructurales en el acceso a la vivienda y apoyar el diseño de políticas urbanas basadas en evidencia. Además, su flexibilidad metodológica posibilita extrapolar el enfoque a otras ciudades o regiones, ajustando los parámetros al contexto socioeconómico y normativo local, lo que refuerza su potencial como instrumento comparativo para la planificación urbana.

4.5. Exploración de gentrificación

La exploración de patrones de gentrificación se abordó mediante un enfoque de aprendizaje automático no supervisado, orientado a identificar estructuras latentes en el parque residencial madrileño.

En efecto, tal como se observó en la figura 11, la estructura del mercado madrileño presenta una fuerte concentración en vivienda multifamiliar, acompañada de una notable dispersión interna en precios y tipologías. Esta heterogeneidad evidencia que las categorías convencionales de tipo de vivienda resultan insuficientes para captar la complejidad del parque residencial. Por este motivo,

se recurre a un análisis de *clustering*, que permite identificar agrupaciones latentes de viviendas y revelar patrones diferenciados de valor, equipamiento y localización asociados a procesos de revalorización y gentrificación urbana.

El propósito fue detectar tipologías de vivienda y áreas con dinámicas de revalorización que pudieran asociarse a procesos de transformación urbana, a partir de los datos integrados en el panel 2011-2024.

Esta fase complementa los resultados del IAV, proporcionando una lectura estructural y espacial del mercado inmobiliario desde la perspectiva del data clustering.

4.5.1. Representación latente del parque residencial

Con el fin de identificar similitudes estructurales entre las viviendas, se generó un **espacio latente continuo** mediante un *autoencoder* implementado en PyTorch, capaz de combinar variables numéricas (superficie, habitaciones, planta, precio) y categóricas (tipo de vivienda, garaje, terraza, ascensor, etc.).

El modelo se entrenó durante 50 épocas con optimizador Adam ($lr = 0.01$), minimizando simultáneamente los errores de reconstrucción de variables numéricas y categóricas.

El resultado fue una matriz de 16 dimensiones en la que cada inmueble se representa como un vector que resume su perfil estructural y funcional, constituyendo la base para el posterior análisis de agrupamiento.

4.5.2. Agrupamiento en el espacio latente

Sobre esta representación comprimida se aplicó una reducción de dimensionalidad mediante UMAP (*Uniform Manifold Approximation and Projection*), con los parámetros $n_neighbors = 30$ y $min_dist = 0.1$, para facilitar la visualización de patrones internos.

Posteriormente, se implementaron diferentes **algoritmos de clustering** con el objetivo de segmentar las viviendas en grupos homogéneos y comparar su coherencia:

- **K-Means:** con selección del número óptimo de clústeres en el rango 2–20, alcanzando el mejor rendimiento con $k = 6$ (*Silhouette* = 0.404).
- **Gaussian Mixture Model (GMM):** con 20 componentes, evaluado según el *Bayesian Information Criterion* (BIC).

- **HDBSCAN:** agrupamiento por densidades locales, que detectó 6 clústeres sin necesidad de fijar k a priori.
- **Bayesian Gaussian Mixture (DP-GMM):** modelo probabilístico no paramétrico que estimó automáticamente 21 componentes.

Para comparar los resultados se utilizaron métricas estándar de calidad de agrupamiento (*Silhouette Score*, *Davies-Bouldin*, *Calinski-Harabasz*) y medidas de correspondencia con los distritos administrativos (*ARI* y *NMI*).

El modelo K-Means con 6 clústeres se seleccionó como la opción final por su equilibrio entre coherencia interna, estabilidad e interpretabilidad, ofreciendo una segmentación consistente con la estructura socioespacial de la ciudad y facilitando la lectura de tipologías residenciales diferenciadas.




Figura 28. Diagrama de flujo de elaboración de clústeres.

4.5.3. Integración espacial y enfoque analítico

Los resultados del modelo K-Means se integraron con la base georreferenciada de viviendas, lo que permitió mapear la distribución espacial de los clústeres dentro del municipio y analizar su correspondencia con variables socioeconómicas y de mercado de cada distrito.

Para interpretar los grupos resultantes se consideraron los siguientes indicadores complementarios:

- Precio mediano del m² (venta y alquiler) entre 2015 y 2024.
- Variación acumulada del precio (2015–2024).
- Renta media distrital (fuentes INE y Ayuntamiento).
- Proporción de viviendas de alto valor (clústeres con precios superiores a la mediana).

El análisis espacial permitió identificar la correspondencia entre los clústeres y las zonas de revalorización, revelando agrupamientos asociados a áreas con precios crecientes, elevada renta y alta densidad de equipamientos (características típicas de procesos de gentrificación incipiente).

Los clústeres vinculados a precios altos, mayor renta y abundancia de equipamientos se concentraron en el eje norte y central, mientras que las tipologías de menor coste y dotación se localizaron principalmente en distritos del sur. Este patrón territorial sugiere la existencia de procesos de revalorización urbana y desplazamiento residencial, elementos característicos de la gentrificación emergente en la ciudad.

4.5.4. Síntesis metodológica

El enfoque de aprendizaje automático no supervisado permitió representar la complejidad del parque residencial madrileño de forma compacta, combinando información estructural, tipológica y espacial. La integración del autoencoder, UMAP y K-Means proporcionó un marco robusto para detectar tipologías residenciales emergentes y patrones de transformación territorial que serán interpretados en el capítulo 5 (Resultados) como posibles indicadores de gentrificación.

4.6. Interfaz web interactiva

Con el objetivo de visualizar, explorar y difundir los resultados del análisis, se desarrolló una interfaz web interactiva mediante la librería Streamlit en Python. Esta aplicación combina el modelado predictivo de precios, los índices de accesibilidad y esfuerzo económico (IAV y Esfuerzo), la exploración de patrones de gentrificación, la visualización interactiva de datos socioeconómicos y la predicción de precios.

La interfaz, titulada “Análisis por distrito y factores determinantes del precio – Madrid”, ofrece un entorno visual dinámico que permite filtrar y comparar información de viviendas por año, distrito y tipo de operación.

4.6.1. Arquitectura y funcionamiento

La aplicación se estructura en tres componentes principales que garantizan su coherencia metodológica y su eficiencia técnica:

Carga y validación de datos:

El sistema importa los registros consolidados del archivo *viviendas_2011_2024.csv*, que contienen precios ajustados, variables socioeconómicas e índices de accesibilidad por distrito.

Antes de ejecutar las visualizaciones, se aplican controles de calidad que verifican la existencia de columnas críticas, la coherencia de tipos de datos y la correcta vinculación de los identificadores territoriales.

Además, se implementa un **sistema de caché local** que optimiza el rendimiento y evita recargas innecesarias durante la navegación.

Filtros interactivos:

Una barra lateral permite seleccionar año, distrito, rango de precios, tipo de vivienda y operación (venta o alquiler).

Los filtros son acumulativos y dinámicos, de modo que el usuario puede crear subconjuntos específicos y observar la proporción de registros seleccionados respecto al total, garantizando la transparencia del análisis.

Estos filtros actúan sobre todas las visualizaciones y métricas de la interfaz, adaptando los resultados en tiempo real.

- **Módulos analíticos avanzados:**
 - **Evolución temporal:** permite graficar la evolución anual de indicadores clave (precio ajustado, IAV, esfuerzo) por distrito, generando series medianas y comparativas.
 - **Visualización UMAP:** proyecta las observaciones en dos dimensiones para representar los clústeres socioespaciales identificados en el análisis de gentrificación.
 - **Mapa de tasa de gentrificación:** muestra la proporción de viviendas pertenecientes a clústeres gentrificados en cada distrito.
- **Visualización de resultados:**
 - **Indicadores clave (KPIs):** se calculan automáticamente medidas de tendencia central (media, mediana, mínimo, máximo).
 - **Diccionario de datos interactivo:** presenta las fórmulas empleadas para calcular cada métrica (IAV, esfuerzo y precio ajustado), integrando ecuaciones explicativas.
 - **Mapa coroplético por distrito:** implementado con *pydeck* y un archivo *GeoJSON*, colorea cada distrito según la mediana de precios, utilizando una escala de cuartiles.
 - **Tabla de resultados:** tres vistas diferenciadas —registros filtrados, resumen estadístico por distrito, y opciones de descarga en formato CSV.
- **Predicción de precios:** se seleccionan características básicas de la vivienda para obtener la estimación del precio ajustado basado en los resultados del modelo predictivo.

Esta arquitectura modular permite cargar y validar datos, aplicar filtros interactivos y visualizar resultados mediante mapas y tablas dinámicas, facilitando el análisis exploratorio y la interpretación visual de patrones inmobiliarios y de accesibilidad.

4.6.2. Módulos analíticos avanzados

En cuanto a sus funcionalidades principales, la interfaz web se estructura en seis módulos complementarios que articulan los procesos de estimación, visualización y análisis de los resultados. Estos módulos están diseñados para funcionar de forma integrada, garantizando tanto la interactividad como la trazabilidad de las operaciones realizadas por el usuario.

En primero de ellos es el módulo de Métricas Principales (KPIs) (figura 29), que muestra un panel resumen de indicadores clave del conjunto de datos filtrado, incluyendo la mediana y la media general de precios, los valores mínimos y máximos, y el número total de distritos considerados.

Estos indicadores se actualizan dinámicamente en función de los filtros aplicados, ofreciendo una visión instantánea de las tendencias del mercado en cada escenario de análisis. El objetivo es

proporcionar una referencia global que complemente la interpretación de los resultados individuales o específicos por distrito.



Figura 29. Streamlit: métricas principales.

El segundo módulo se trata del diccionario de datos interactivo, orientado a la transparencia metodológica y a la comprensión de los indicadores utilizados. En esta sección se presentan las fórmulas matemáticas empleadas para calcular los índices de accesibilidad y esfuerzo económico, expresadas en formato LaTeX. Entre ellas se incluyen el Índice de Accesibilidad a la Vivienda (IAV), tanto para compra como para alquiler; y los indicadores de esfuerzo, que representan los años o el porcentaje de renta necesarios para acceder a una vivienda. Asimismo, se introduce la fórmula del precio ajustado, obtenida mediante el método descrito anteriormente.

El tercer módulo corresponde al mapa coroplético interactivo, el cual permite visualizar espacialmente las variables socioeconómicas o inmobiliarias seleccionadas (por ejemplo, el precio mediano o el IAV) a través de un mapa dinámico por distritos.

La escala de color se adapta automáticamente al rango de valores filtrado, lo que facilita la comparación visual entre áreas con diferentes niveles de accesibilidad o precios. Esta visualización se apoya en tecnologías de representación geoespacial integradas en Plotly y GeoJSON, lo que garantiza fluidez y precisión cartográfica.

El quinto módulo es el de análisis de gentrificación, que integra la proyección bidimensional de las observaciones mediante UMAP (figura 32) y la clasificación mediante clustering obtenida con el algoritmo K-Means.

Esta sección permite visualizar la distribución espacial y estructural de los distintos grupos socioeconómicos identificados (clústeres), representados por colores diferenciados. Cada clúster corresponde a un tipo de tejido residencial con características comunes, desde viviendas familiares consolidadas hasta tipologías más modernas o de carácter periférico.




Figura 32. Streamlit: clústeres visualizados con UMAP.

El análisis de agrupamientos se complementa con un mapa que refleja la **proporción de viviendas en distritos gentrificados** (figura 33), proporcionando una interpretación visual del proceso de transformación urbana en Madrid.

Tasa de gentrificación por distrito (%) — KMeans

Fuente: clusters.csv · Algoritmo: KMeans · Clusters gentrificadores: 0, 1, 3, 4




Figura 33. Mapa de tasa de gentrificación por distrito con K-Means.

El último es el módulo de predicción de precios (figura 34), que ofrece un formulario interactivo en el que el usuario puede introducir las características básicas de una vivienda —como tamaño, distrito, año y tipo de operación (venta o alquiler)— para obtener una estimación del precio ajustado. Este cálculo se basa en los resultados del modelo predictivo entrenado durante la fase de análisis, lo que permite explorar de manera práctica el comportamiento estimado del mercado inmobiliario madrileño.




Figura 34. Streamlit: predicción de precios según características.

4.6.3. Usabilidad y experiencia de usuario

La interfaz se diseñó con un enfoque minimalista e intuitivo, priorizando la claridad visual y la facilidad de navegación: los filtros permanecen fijos en la barra lateral, el mapa ocupa la parte central de la pantalla y los indicadores numéricos se muestran en tarjetas superiores.

El diseño prioriza la claridad visual y la facilidad de navegación, permitiendo que tanto usuarios técnicos como no técnicos interpreten los resultados de forma intuitiva. Su carácter modular y escalable la convierte en una herramienta transferible a contextos institucionales de análisis urbano.

4.6.4. Innovación metodológica y valor añadido

Desde el punto de vista metodológico, el desarrollo del Streamlit incorpora tres aportes principales:

- **Modelado predictivo de precios**, utilizando *LGBM* con datos históricos del periodo 2015-2022.
- **Cálculo del IAV y del esfuerzo económico**, indicadores que evalúan la accesibilidad y la carga financiera asociada a la vivienda.
- **Identificación de patrones de gentrificación**, mediante la proyección UMAP y el agrupamiento K-Means que permite clasificar tipologías urbanas.

Estas innovaciones, integradas en un mismo entorno interactivo, confieren a la herramienta un carácter técnicamente robusto y metodológicamente innovador, traduciendo análisis estadísticos complejos en visualizaciones comprensibles y dinámicas.

El valor añadido de la interfaz web radica en su capacidad para conectar la investigación académica con la práctica de la planificación urbana. Permite analizar desigualdades territoriales, identificar áreas vulnerables, evaluar políticas de vivienda y comunicar resultados de manera transparente. Su estructura modular, su escalabilidad y su potencial de replicabilidad hacen de esta herramienta un recurso estratégico para la toma de decisiones basadas en datos y la gestión territorial sostenible.

En la figura 35 se puede observar el flujo de funcionamiento del software para la interfaz web.




Figura 35. Diagrama de flujo del funcionamiento de la interfaz web de Streamlit.

5. Resultados

Este capítulo presenta los principales resultados empíricos del proyecto, obtenidos a partir del modelo predictivo de precios, el Índice de Accesibilidad a la Vivienda (IAV) y el análisis no supervisado orientado a la detección de patrones de gentrificación.

5.1. Evaluación de los modelos predictivos

El modelo final, *Light Gradient Boosting Machine* (LGBM), optimizado mediante búsqueda bayesiana (Optuna), alcanzó un R^2 superior a 0,9 y un MAPE inferior al 10 % en el conjunto de prueba (2023-2024), mostrando un rendimiento altamente satisfactorio y estable a lo largo del tiempo. Esto implica, en términos de planificación urbana, que permite proyectar precios distritales con fiabilidad para simular escenarios de accesibilidad.

Los resultados detallados y las visualizaciones correspondientes (relación entre precios reales y predichos, distribución de errores e importancia de variables) se presentan en la sección 4.3.1.6 (Entrenamiento final y evaluación).

En síntesis, los modelos mantienen una precisión superior al 90 % en la predicción de precios interanuales, con una dispersión mínima entre los distritos y un error medio absoluto inferior a 20.000 € (en venta) en la mayoría de los casos. Las desviaciones más elevadas se concentran en el segmento de viviendas de lujo, donde el número de observaciones es reducido y la variabilidad de precios mayor.

El análisis de importancia de variables confirmó que los predictores más influyentes fueron el ratio vs distrito, el precio promedio del año anterior y el tamaño de vivienda para el modelo de venta, indicando que se tiene más en cuenta la relación de los precios con la media y la superficie como predictores del precio. Para el modelo de alquiler, el tamaño, la tendencia de precios del distrito y el ratio vs distrito se mantienen como los principales predictores que, de manera similar a la venta, indican que, para el modelo, los precios dependen más del tamaño y de la tendencia propia del distrito.

Estas variables reflejan que el modelo integra de forma efectiva factores físicos y contextuales, capturando tanto las características intrínsecas del inmueble como la dinámica socioeconómica del entorno.

En conjunto, los resultados confirman que los modelos predictivos son robustos, generalizables y explicativos, y constituyen una base sólida para el análisis posterior de accesibilidad y gentrificación.

En síntesis, los modelos muestran una alta capacidad predictiva y una estabilidad temporal adecuada, lo que lo convierte en una herramienta sólida para generar precios ajustados por contexto territorial. Esta fiabilidad permite utilizar sus resultados como base del IAV y de los análisis espaciales de gentrificación desarrollados posteriormente.

5.2. Resultados del IAV

El IAV permitió cuantificar la capacidad económica de los hogares madrileños para cubrir el coste de una vivienda mínima, diferenciando entre compra y alquiler. Los resultados evidencian contrastes espaciales y socioeconómicos significativos, así como una dualidad estructural entre ambos regímenes de acceso.

5.2.1. Panorama general

El IAV revela un patrón desigual en la accesibilidad habitacional de la ciudad de Madrid, aunque con una **tendencia diferenciada entre compra y alquiler**.

En la modalidad de compra, los valores del índice se sitúan en torno al umbral de accesibilidad (mediana $\approx 1,1$), lo que indica que los ingresos de los hogares apenas alcanzan el nivel mínimo necesario para la adquisición de una vivienda.

Si bien este resultado refleja una ligera mejora respecto a etapas anteriores de alta inaccesibilidad, sigue evidenciando una situación de equilibrio frágil, donde cualquier incremento de precios o disminución de renta puede traducirse en exclusión del mercado de propiedad. A su vez, se debe tener en cuenta que, al no tener en consideración los gastos anuales y el ahorro necesario para el acceso a una hipoteca, el índice puede estar mostrando valores más altos que la realidad.

Por el contrario, el IAV de alquiler muestra valores considerablemente más altos (mediana $\approx 5,8$; media $\approx 6,1$), lo que a primera vista podría interpretarse como una accesibilidad elevada. Sin embargo, esta lectura es engañosa: un IAV superior a 1 no implica mayor capacidad adquisitiva, sino que en este caso denota una desproporción entre el cálculo basado en renta del hogar y el precio por m² mensual.

En otras palabras, el alquiler solo resulta viable bajo estructuras de renta compartida o acumulada (parejas, familias o convivencias), más que por la solvencia individual.

Para interpretar correctamente ambos indicadores:

- **IAV < 1:** Inaccesibilidad estructural: la renta del hogar no cubre el coste estimado.
- **IAV $\approx$ 1:** Accesibilidad precaria o límite: equilibrio inestable entre ingresos y precio.
- **IAV > 1:** Accesibilidad aparente o sobreestimada, frecuentemente sustentada por rentas combinadas.

5.2.2. Esfuerzo económico y sostenibilidad

La interpretación del IAV se complementa con el análisis del esfuerzo económico requerido para adquirir o alquilar una vivienda.

Esfuerzo de compra: la mediana se sitúa en $\approx 5,1$ años de renta bruta del hogar, lo que ubica al mercado madrileño en el límite entre accesibilidad moderada y grave inaccesibilidad según los estándares internacionales. (UN-Habitat, 2024) Esto significa que un hogar medio necesitaría más

de cinco años de ingresos íntegros para comprar una vivienda mínima, sin considerar gastos financieros o intereses hipotecarios.

Esfuerzo de alquiler: alcanza una mediana de $\approx 17\%$ de la renta anual, aunque el rango intercuartílico ($\approx 13\text{-}22\%$) y los valores extremos muy altos indican que una parte significativa de los hogares enfrenta sobrecarga de costes (por encima del $30\text{-}40\%$ de la renta neta). Este patrón confirma que, pese a los IAV elevados, el alquiler no es sostenible para una proporción creciente de hogares, especialmente los de ingresos bajos o unipersonales.

5.2.3. Accesibilidad por distrito (alquiler)

Los resultados espaciales confirman un gradiente territorial claro entre el norte y el sur de la ciudad, reflejando la desigual distribución de la capacidad económica de los hogares madrileños frente al coste del alquiler.




Figura 36. Índice de Accesibilidad Media por distritos – Alquiler

El IAV de alquiler evidencia un patrón territorial desigual en la ciudad de Madrid, con una media de 6,08 y mediana de 5,83. Los distritos del norte y noroeste (como Chamartín, Fuencarral-El Pardo y Moncloa-Aravaca) presentan los valores más altos del índice, reflejando una mayor capacidad económica relativa de sus hogares frente al coste del alquiler.

En cambio, los distritos del centro y sur (Centro, Puente de Vallecas y Carabanchel) muestran niveles de accesibilidad notablemente menores, resultado de rentas más bajas y presión inmobiliaria elevada.

Este gradiente norte-sur confirma la persistencia de la desigualdad habitacional: mientras los hogares de renta alta logran sostener el alquiler sin sobrecarga significativa, algunos de los de menores ingresos deben destinar más del 30 % de su renta a la vivienda, situándose en riesgo de sobreesfuerzo económico.

Los contrastes territoriales refuerzan la necesidad de políticas de alquiler asequible dirigidas a los distritos del sur, donde el acceso a la vivienda supera los umbrales de sostenibilidad financiera.

5.2.4. Accesibilidad por distrito (compra)

En la modalidad de compra, el IAV presenta valores cercanos al umbral de accesibilidad (mediana $\approx 1,1$), lo que indica que los hogares madrileños se encuentran en una situación límite para acceder a una vivienda en propiedad.




Figura 37. Índice de Accesibilidad Media por distritos – Compra

Los distritos del norte y noroeste (como Chamartín, Moncloa-Aravaca y Fuencarral-El Pardo) registran los valores más altos del índice, evidenciando ligeras ventajas relativas derivadas de rentas más elevadas.

Por el contrario, algunos distritos del sur y suroeste (como Carabanchel, Usera y Puente de Vallecas) presentan un IAV más bajo, lo que refleja inaccesibilidad estructural incluso para viviendas mínimas.

En términos generales, se debe tener en cuenta que el cálculo del IAV, por sus limitaciones, tiene un valor que está por encima de la realidad. Por tanto, la compra de vivienda en Madrid se mantiene fuera del alcance real de la mayoría de los hogares, salvo en aquellos con niveles de renta altos o acumulación de ingresos. La brecha norte-sur observada en el alquiler se repite, aunque de forma menos pronunciada, consolidando un patrón de desigualdad persistente en el acceso a la propiedad.

La estabilidad aparente del IAV de compra oculta una accesibilidad precaria: los hogares medios se sitúan en el límite entre la capacidad de adquisición y la exclusión del mercado inmobiliario.

5.2.5. Comparativa compra vs alquiler

El análisis comparativo entre las dos modalidades del IAV revela una brecha estructural profunda entre los regímenes de compra y alquiler, que sintetiza la dualidad del mercado residencial madrileño.




Figura 38. Distribución del IAV compra vs alquiler.

El IAV de compra se concentra en valores cercanos a 1, con baja dispersión, lo que indica una accesibilidad limitada pero relativamente estable. Los hogares madrileños se sitúan en un equilibrio frágil, donde pequeños cambios en el precio o en la renta pueden impedir el acceso a la vivienda en propiedad.

En cambio, el IAV de alquiler alcanza una mediana de 5,83 y una mayor variabilidad territorial, evidenciando una accesibilidad aparente más que real. Este resultado responde a que el índice se calcula sobre la renta total del hogar, lo que sobreestima la capacidad adquisitiva cuando el alquiler se sostiene mediante ingresos compartidos o acumulados.

La diferencia entre ambos regímenes —más del 430 % entre las medianas de compra y alquiler— refleja una transición estructural hacia el alquiler como vía predominante de acceso a la vivienda, especialmente bajo modalidades compartidas. Al mismo tiempo, la relativa homogeneidad del IAV de compra entre distritos sugiere una tendencia a la estabilización y revalorización del precio, asociada a la demanda inversora y a dinámicas incipientes de gentrificación.

En conjunto, los resultados confirman que la compra sigue siendo estructuralmente inaccesible para la mayoría de los hogares, mientras que el alquiler, aunque más extendido, no garantiza sostenibilidad financiera a largo plazo. La vivienda en Madrid se sostiene, en gran medida, sobre la acumulación de rentas familiares o compartidas, más que sobre la capacidad económica individual.

El contraste entre la aparente accesibilidad del alquiler y la inaccesibilidad persistente de la compra resume la paradoja del mercado madrileño: la vivienda es alcanzable únicamente mediante ingresos combinados.

5.2.6. Evolución temporal (alquiler)

La evolución temporal del IAV en régimen de alquiler muestra una tendencia claramente descendente entre 2015 y 2019, seguida de una recuperación gradual a partir de 2020, aunque sin alcanzar los niveles iniciales.




Figura 39. Evolución del IAV por Distrito - Alquiler

El descenso observado en la primera etapa refleja el impacto combinado del aumento del precio del alquiler y la pérdida de poder adquisitivo de los hogares, especialmente en los distritos del centro y sur de Madrid, donde el esfuerzo económico superó los umbrales de sostenibilidad definidos por Eurostat (2023), que establece como referencia un límite del 30–40 % de la renta disponible para evitar la sobrecarga habitacional.

A partir de 2020 se evidencia un ligero repunte del IAV, vinculado a un ajuste socioeconómico más que a una mejora estructural. Según datos del Instituto Nacional de Estadística, la proporción de hogares con más de un perceptor de ingresos aumentó de forma sostenida en la última década, pasando de aproximadamente el 46 % en 2011 al 58 % en 2024. Este fenómeno indica que la recuperación del IAV responde, en gran medida, a la acumulación de rentas dentro del hogar como estrategia adaptativa frente a la inflación del mercado del alquiler.

En coherencia con los planteamientos de Zukin sobre la reconfiguración social del espacio urbano, este comportamiento no expresa una mejora estructural, sino una adaptación colectiva al contexto de precios crecientes y presión residencial. Los hogares con ingresos múltiples se consolidan como el principal soporte del acceso al alquiler, mientras que la capacidad adquisitiva individual continúa deteriorándose.

En síntesis, el incremento reciente del IAV no refleja un aumento real de la accesibilidad, sino una resistencia social frente al encarecimiento habitacional, manteniendo vigente el gradiente norte–sur

de desigualdad: los distritos del norte registran una recuperación más sólida, mientras que los del sur permanecen en niveles críticos de accesibilidad.

5.2.7. Accesibilidad y esfuerzo económico en la compra de vivienda

El análisis conjunto del IAV y del esfuerzo económico muestra que la compra sigue siendo estructuralmente inaccesible, mientras que el alquiler, aunque más extendido, implica riesgos crecientes de sobrecarga financiera.

En la compra, el IAV medio ($\approx 1,1$) refleja una accesibilidad límite y un esfuerzo equivalente a unos siete años de renta del hogar, superando los estándares de UN-Habitat, que consideran asequible un valor inferior a tres años. Esta relación confirma que el acceso a la propiedad depende casi exclusivamente de hogares con doble ingreso o rentas altas.

En el alquiler, el IAV más elevado ($\approx 5,8$) no implica mayor capacidad adquisitiva, sino una sobreestimación derivada del cálculo por renta del hogar. El esfuerzo medio ($\approx 21\%$ de la renta anual) se aproxima a los umbrales de sobrecarga habitacional definidos por Eurostat y la OECD (30–40 %), y supera dichos límites en varios distritos del sur, como Carabanchel o Usera.

En conjunto, estos resultados evidencian que la accesibilidad teórica y la sostenibilidad real avanzan en direcciones opuestas: la vivienda en Madrid solo es viable mediante la acumulación de rentas familiares o compartidas, en coherencia con la reconfiguración social del hogar descrita por Zukin.

5.2.8. Comparación del IAV con variables socioeconómicas y demográficas

El análisis de correlaciones de Spearman (figura 40) confirma la relación del IAV con las condiciones socioeconómicas y demográficas locales. Los resultados, estadísticamente significativos ($p < 0,05$), evidencian que la accesibilidad habitacional en Madrid está determinada por la combinación de factores de renta, empleo y estructura urbana.




Figura 40. Correlación de Spearman con IAV.

Se observa una correlación positiva entre el IAV de alquiler y la renta media del hogar ($p = 0,68$), lo que indica que la accesibilidad aumenta en distritos con mayores ingresos. Por el contrario, el paro registrado muestra una correlación negativa moderada ($p = -0,58$), reforzando la relación inversa entre accesibilidad y vulnerabilidad laboral, en línea con los estudios sobre segregación urbana en contextos europeos (Zukin, 1987; Eurostat, 2023).

La relación inversa fuerte con el esfuerzo económico ($p = -0,93$) confirma que el incremento del porcentaje de renta destinado a la vivienda reduce casi proporcionalmente el nivel de accesibilidad, validando la coherencia interna del indicador. Asimismo, se observan correlaciones negativas con la densidad poblacional ($p = -0,45$) y con la superficie de zonas verdes ($p = -0,52$), lo que refleja que las áreas más densamente urbanizadas y con menor disponibilidad de espacio público presentan los niveles más bajos de accesibilidad.

En cuanto a las variables demográficas, se identifica una asociación positiva moderada entre el IAV y la esperanza de vida y el índice de envejecimiento, lo que sugiere que los distritos con población

de mayor edad suelen concentrar mejores condiciones socioeconómicas y, por tanto, una accesibilidad ligeramente superior.

En conjunto, las correlaciones confirman que el IAV sintetiza de forma coherente la interacción entre renta, empleo y entorno urbano, consolidándose como un indicador robusto de desigualdad habitacional en el contexto metropolitano madrileño.

5.3. Patrones de gentrificación y tipologías detectadas

El análisis no supervisado aplicado sobre el espacio latente de viviendas permitió identificar seis tipologías residenciales con características estructurales, económicas y espaciales diferenciadas. Estos grupos reflejan las distintas realidades del mercado residencial madrileño y sirven como base para comprender los procesos de revalorización y gentrificación que afectan a la ciudad.

5.3.1. Tipologías residenciales identificadas

Mediante el modelo **K-Means con $k = 6$** , se definieron seis clústeres que sintetizan la estructura interna del parque de vivienda, estas tipologías no solo diferencian precios, sino también estilos de vida y fases de renovación urbana.

Tabla 9. Clústeres definidos por el modelo K-Means.

CLÚSTER	DESCRIPCIÓN GENERAL	CARACTERÍSTICAS PRINCIPALES	DISTRITOS PREDOMINANTES	% DE VIVIENDAS POR CLÚSTER
C0	Apartamentos familiares en zonas consolidadas	Tamaño medio ($\approx 104 \text{ m}^2$), 2–3 habitaciones, precios medios-altos, alto porcentaje exterior y ascensor.	Retiro, Salamanca, Chamberí	33,9%
C1	Vivienda mediana en alquiler en zonas centrales	Viviendas de 80 m^2 , 2 habitaciones, bajo precio, alto porcentaje de alquiler.	Arganzuela, Tetuán, Chamartín	28,3%
C2	Viviendas de lujo o gran superficie	Chalets y tipologías unifamiliares, 300 m^2 promedio, precios muy altos.	Moncloa-Aravaca, Hortaleza, Fuencarral-El Pardo	4.1%

C3	Vivienda económica y compacta	65 m ² promedio, 2 habitaciones, precios bajos, baja dotación de equipamiento.	Puente de Vallecas, Carabanchel, Usera	20.7%
C4	Vivienda moderna y bien equipada en zonas centrales	100 m ² , alto equipamiento (terraza, ascensor), precios medios-altos.	Centro, Salamanca, Tetuán	8.4%
C5	Vivienda periférica estándar bien dotada	Viviendas de 90 m ² , garaje y trastero frecuentes, precio medio, ubicadas en expansión periférica.	Hortaleza, Vicálvaro, Villa de Vallecas	4.6%




Figura 41. Distribución de clústeres en el espacio latente (UMAP).

La proyección UMAP del espacio latente muestra seis agrupaciones bien diferenciadas. El clúster C0 aparece como un grupo central y compacto, representando viviendas familiares de tamaño medio y características equilibradas. El clúster C1 se distribuye de forma más dispersa, reflejando viviendas medianas destinadas al alquiler. El clúster C2 forma una región aislada y bien delimitada, correspondiente a viviendas de gran tamaño y alto valor económico. Los clústeres C3 y C5 ocupan posiciones periféricas y fragmentadas, asociadas a viviendas pequeñas o de carácter residencial reciente. Finalmente, el clúster C4 se ubica en una zona superior y separada, concentrando viviendas reformadas y de gama media-alta en áreas céntricas.

5.3.2. Distribución espacial y segmentación territorial

El mapa revela una clara polarización territorial:

- Los clústeres **C0, C1 y C4** se concentran en los distritos centrales (Centro, Salamanca, Chamberí, Retiro y Arganzuela), caracterizados por una alta densidad y procesos de rehabilitación urbana.
- Los clústeres **C2 y C5** predominan en las zonas del norte y este (Moncloa-Aravaca, Hortaleza, Fuencarral-El Pardo, Vicálvaro), asociados a desarrollos de alto valor y vivienda unifamiliar reciente.
- El clúster **C3**, vinculado a vivienda económica, domina en el sur (Puente de Vallecas, Carabanchel, Villaverde y Usera), reflejando la persistencia de desigualdades estructurales.




Figura 42. Distribución espacial de los clústeres residenciales por distrito

Este patrón reproduce la segmentación socioeconómica norte-sur observado en el IAV, pero añade una capa tipológica que permite comprender las distintas formas de ocupación residencial y transformación urbana.

5.3.3. Tasa de gentrificación por composición de clústeres

Para cuantificar la intensidad relativa de los procesos de gentrificación, se definió una tasa de gentrificación distrital basada en la proporción de viviendas pertenecientes a los clústeres asociados con tipologías de revalorización urbana. Esta tasa permite estimar el grado en que cada distrito concentra vivienda susceptible de procesos de sustitución o valorización.

Inicialmente, se consideraron como clústeres-gentrificadores los grupos C0, C1 y C4, vinculados a viviendas reformadas o de alto valor en áreas centrales. Los grupos C2, C3 y C5 fueron clasificados como residenciales tradicionales.

La tasa de gentrificación se calculó según la siguiente expresión:

$$Tasa_{gentrificación} = \frac{Viviendas\ gentrificadas}{Viviendas\ residenciales}$$

De este modo, la tasa representa la proporción de viviendas gentrificadas sobre el total de viviendas residenciales en cada distrito. Valores altos indican una mayor intensidad de procesos de revalorización urbana, mientras que valores bajos reflejan mercados más estables o periféricos.

Desde el punto de vista metodológico, es importante señalar que la clasificación de viviendas gentrificadas depende del agrupamiento generado por el modelo K-Means, por lo que la tasa es sensible al parámetro k. Un número menor de clústeres tiende a agrupar zonas heterogéneas, reduciendo la tasa estimada; en cambio, valores más altos de k incrementan la capacidad del modelo para detectar focos incipientes de gentrificación y capturar transiciones espaciales más finas.

Los resultados muestran que los distritos de Salamanca, Retiro y Chamberí registran las tasas más elevadas, seguidos por Chamartín y Arganzuela, donde los procesos de revalorización urbana están más consolidados. En contraste, los distritos del sur y sureste —Carabanchel, Latina, Vallecas y Villaverde— presentan tasas bajas, lo que evidencia una marcada polarización espacial del fenómeno entre el centro y la periferia de la ciudad.




Figura 43. Tasa de gentrificación por distrito según dos métodos: composición de clústeres y precio medio relativo.

Los resultados podrían emplearse como indicador temprano para la detección de áreas en transición urbana.

5.3.4. Revisión del modelo e inclusión del clúster 3

Tras el análisis inicial, se observó que el clúster 3 (vivienda económica y compacta), aunque identificado como tipología asequible, presenta características propias de gentrificación incipiente:

- Viviendas pequeñas de 60-70 m², con dos habitaciones y bajo coste.
- Ubicadas en distritos populares (Carabanchel, Vallecas, Usera, Villaverde).
- Alta rentabilidad en el mercado del alquiler y creciente interés inversor.

Debido a estos rasgos, el modelo se ajustó para incluir el clúster 3 dentro del grupo gentrificado, junto con los clústeres 0, 1 y 4.

La inclusión del clúster 3 provoca un incremento de las tasas en distritos del sur y sureste, reflejando la expansión del proceso hacia áreas residenciales más asequibles. Aunque la gentrificación sigue

siendo más intensa en el eje centro-norte, los resultados sugieren una difusión gradual del fenómeno hacia barrios tradicionalmente populares.

En el nuevo escenario (Figura 44), los distritos con mayores tasas son Centro, Salamanca, Chamberí y Retiro, mientras que Carabanchel, Latina y Vallecas muestran valores moderados pero crecientes, señal de una transición urbana en curso.




Figura 44. Tasa de gentrificación revisada (modelo 0,1,3,4).

5.3.5. Casos destacados

El análisis conjunto permite distinguir dos dinámicas complementarias de gentrificación.

- Gentrificación consolidada en los distritos centrales (Centro, Salamanca, Chamberí, Retiro), caracterizada por vivienda reformada, alta demanda y sustitución social avanzada.
- Gentrificación emergente en distritos del sur y este (Carabanchel, Latina, Puente de Vallecas, Villaverde), vinculada al alquiler intensivo de vivienda económica y a la inversión en unidades pequeñas de alta rotación.

Un caso intermedio es Tetuán, que combina zonas tradicionales de renta media-baja con áreas de fuerte revalorización, especialmente en el eje de Bravo Murillo.

Su tasa de gentrificación aumenta significativamente al incluir el clúster 3, reflejando su papel como puente urbano entre la gentrificación consolidada del centro y la emergente del sur.

5.3.6. Síntesis de resultados

Por lo tanto, a partir de los resultados del análisis de clustering y gentrificación, pueden establecerse las siguientes conclusiones. En primer lugar, El modelo K-Means con $k = 6$ logra una segmentación coherente del mercado residencial madrileño, diferenciando tipologías asociadas a niveles de renta y equipamiento.

Asimismo, la gentrificación se manifiesta como un proceso dual: consolidado en el centro y emergente en la periferia, impulsado por la inversión en vivienda de menor tamaño y mayor accesibilidad.

No obstante, la incorporación del clúster 3 amplía la sensibilidad del modelo, permitiendo detectar zonas en transición y nuevos focos de rentabilidad urbana.

De esta forma los resultados son consistentes con las tendencias identificadas en el IAV, confirmando la interrelación entre accesibilidad, renta y transformación residencial.

Finalmente, en el siguiente capítulo se discuten las implicaciones de estos hallazgos para la planificación urbana y las políticas de vivienda.

6. Discusión

El conjunto de resultados obtenidos en este trabajo permite interpretar de manera integral las dinámicas actuales del mercado inmobiliario madrileño, las desigualdades en el acceso a la vivienda y la presencia de procesos de revalorización urbana asociados a la gentrificación.

Desde la perspectiva de la ciencia de datos, el estudio demuestra la viabilidad de aplicar modelos predictivos y no supervisados al análisis urbano, mientras que, desde el punto de vista social y territorial, pone de relieve los límites estructurales del modelo habitacional contemporáneo y las tensiones entre crecimiento inmobiliario, accesibilidad y equidad. En este contexto, el IAV se consolida como un indicador integral para medir la desigualdad territorial, al combinar dimensiones económicas, demográficas y morfológicas del espacio urbano.

6.1. Implicaciones para la planificación urbana

Los hallazgos del IAV y del análisis de gentrificación aportan información relevante para la planificación urbana y las políticas públicas de vivienda en Madrid. El gradiente norte-sur evidenciado en el IAV confirma la concentración del capital inmobiliario y de la renta en los distritos del norte y noroeste, frente a la vulnerabilidad estructural de los del sur. Sin embargo, los resultados muestran que incluso en los distritos con mejores indicadores económicos la accesibilidad a la vivienda se mantiene en equilibrio precario, mientras que en el sur la presión del mercado y los bajos ingresos consolidan situaciones de sobre esfuerzo y exclusión residencial.

El IAV de alquiler, aunque mantiene valores superiores a 1, no refleja una mejora real de la accesibilidad, sino una sostenibilidad aparente basada en la acumulación de rentas dentro del hogar. Este fenómeno revela un cambio estructural en el modelo de acceso a la vivienda, en el que la cohabitación o la combinación de ingresos se convierten en estrategias necesarias para sostener el alquiler en un mercado tensionado. La incorporación del IAV en este marco analítico ofrece una visión cuantitativa y replicable de la desigualdad habitacional, facilitando la priorización de políticas públicas orientadas a la equidad territorial.

Los clústeres asociados a la gentrificación (C0, C1, C3 y C4) muestran que la revalorización urbana con frecuencia se traduce en presión sobre la población de menores ingresos, generando procesos de exclusión residencial. Las estrategias de regeneración urbana deben incorporar mecanismos de protección frente al desplazamiento, como la limitación de la especulación, la regulación del alquiler turístico y la promoción de vivienda pública en áreas centrales, evitando que la mejora urbana derive en desigualdad.

Por último, la integración del modelo predictivo, el IAV y las técnicas de clustering en una interfaz visual demuestra el potencial de la ciencia de datos para la gestión urbana y la toma de decisiones basadas en evidencia. Este enfoque permite identificar patrones espaciales de riesgo, anticipar desequilibrios y evaluar la efectividad de las políticas públicas en tiempo real, ofreciendo una herramienta de análisis replicable para la gobernanza territorial.

En síntesis, los resultados invitan a repensar la planificación urbana de Madrid desde una perspectiva de justicia territorial, en la que la accesibilidad no dependa exclusivamente del poder adquisitivo individual, sino de un modelo de ciudad que garantice la sostenibilidad residencial, promueva la vivienda asequible y reduzca la necesidad de estrategias de pago mediante ingresos múltiples como condición de permanencia en la ciudad.

6.2. Limitaciones y desafíos metodológicos

A pesar de la solidez del marco analítico, el estudio presenta ciertas limitaciones que deben tenerse en cuenta en la interpretación de los resultados.

Uso de rentas medias distritales. El IAV se calculó a partir de la renta media del hogar por distrito, lo que permite una comparación territorial consistente, pero no refleja la heterogeneidad intra distrital ni las desigualdades entre tipos de hogar. Los valores de accesibilidad podrían estar sobrestimados en zonas con alta concentración de hogares con ingresos múltiples y subestimados en áreas con predominio de hogares unipersonales o de bajos ingresos, lo que introduce cierto sesgo en la evaluación de la accesibilidad real.

Dependencia de fuentes secundarias. La calidad del modelo predictivo depende de los datos procedentes de Idealista, que reflejan la oferta del mercado y no necesariamente la demanda efectiva. La exclusión de operaciones informales o no declaradas podría afectar parcialmente la representatividad de los resultados, especialmente en distritos donde el alquiler informal tiene mayor presencia.

Simplificación del modelo de vivienda mínima. La adopción de una superficie mínima de 40 m² facilitó la comparación temporal y territorial, pero no considera las variaciones en la estructura del hogar ni las preferencias de tamaño, localización o tipología habitacional, lo que puede limitar la interpretación del IAV en contextos con mayor diversidad morfológica.

Estimación del esfuerzo económico. El cálculo del esfuerzo de compra y alquiler se realizó sobre la renta declarada del hogar, sin considerar los efectos de inflación, endeudamiento o gastos asociados a suministros, lo que podría subestimar el nivel real de sobrecarga financiera en los hogares más vulnerables.

Limitaciones del clustering. Aunque la combinación de UMAP y K-Means ofrece una representación robusta de los patrones espaciales, los resultados podrían variar con otros métodos (p. ej., DBSCAN o enfoques mixtos con datos cualitativos). Además, el fenómeno de la gentrificación trasciende las dimensiones físicas o económicas e incorpora dinámicas culturales, simbólicas y sociales que exceden el alcance del modelo empleado.

Falta de datos de calidad. Otro aspecto para considerar es la incompletitud de las series de datos utilizadas. No se cuenta con información completa para todos los años analizados, especialmente en lo referente a los precios históricos y otras variables relevantes del mercado inmobiliario. Esta limitación puede afectar la comparabilidad temporal de los resultados y la precisión de las

estimaciones, dado que algunas fluctuaciones o tendencias pasadas podrían no estar plenamente representadas en el análisis. Al tener acceso a datos socioeconómicos completos únicamente para 8 años consecutivos, no se pudo extrapolar las predicciones para observar cambios a mayor plazo.

En conjunto, estas limitaciones no invalidan los resultados, pero invitan a una lectura crítica y contextualizada del modelo, resaltando la necesidad de integrar datos más desagregados, información socioeconómica actualizada y variables cualitativas que permitan una comprensión más completa de las desigualdades habitacionales en el ámbito urbano.

6.3. Aporte de valor

El trabajo aporta tres contribuciones principales al campo del análisis urbano mediante ciencia de datos.

En primer lugar, se destaca la integración metodológica, que permitió desarrollar un flujo analítico completo —desde la recolección automatizada de datos hasta la modelización y visualización—. Este proceso demostró la viabilidad de aplicar metodologías de ciencia de datos al estudio territorial y su potencial de réplica en otros contextos urbanos o a escalas metropolitanas.

En segundo lugar, se propone un indicador sintético de accesibilidad habitacional (IAV), concebido como una herramienta transparente y adaptable a diferentes niveles territoriales. El IAV combina variables de renta, esfuerzo económico y precios de vivienda en un marco comparativo único, permitiendo identificar desigualdades estructurales en el acceso a la vivienda y ofrecer una medida replicable de accesibilidad y vulnerabilidad habitacional.

Por último, se presenta la identificación empírica de la gentrificación, lograda mediante la combinación del análisis latente y la clasificación en clústeres. Esta integración metodológica permite detectar patrones emergentes de revalorización urbana y ofrece una base sólida para monitorizar transformaciones territoriales en tiempo casi real.

6.4. Futuras líneas de investigación

Entre las líneas de investigación derivadas del estudio, se propone incorporar variables de movilidad residencial y microdatos censales que permitan analizar los desplazamientos poblacionales asociados a los procesos de gentrificación y exclusión residencial. Asimismo, resulta de interés integrar el análisis semántico de los anuncios inmobiliarios, mediante técnicas de procesamiento del lenguaje natural (NLP), con el fin de captar el discurso de valorización urbana y su relación con la demanda de vivienda.

Una de las ideas iniciales del proyecto fue extender el análisis de clústeres a localidades periféricas del Área Metropolitana de Madrid, como Alcobendas, Getafe o Leganés. Sin embargo, esta ampliación no pudo completarse. Por ello, se propone como línea futura la evaluación ampliada que incorpore estos municipios, con el fin de obtener una visión más exhaustiva de los procesos de gentrificación y de las dinámicas de accesibilidad residencial.

Finalmente, se plantea el desarrollo de un sistema de monitorización continua, basado en paneles (*dashboards*) interactivos o plataformas abiertas, que conecte el IAV y los clústeres con indicadores de política habitacional. Esta línea contribuiría a fortalecer la gobernanza de datos urbanos y a generar herramientas dinámicas para el seguimiento de la accesibilidad y la equidad territorial.

7. Conclusiones

El presente trabajo analizó las dinámicas del mercado inmobiliario madrileño desde una perspectiva de ciencia de datos aplicada al territorio, con el propósito de comprender las desigualdades en el acceso a la vivienda y los procesos de revalorización urbana asociados a la gentrificación.

El proyecto se sustenta en la integración de múltiples fuentes de información, combinando datos de mercado en tiempo real con indicadores oficiales y socioeconómicos. Este enfoque permitió analizar de manera integral las dinámicas de precios y las desigualdades territoriales en el acceso a la vivienda en Madrid, aportando una visión empírica y actualizada de las transformaciones del mercado residencial.

A través de la integración de modelos predictivos, indicadores sintéticos y técnicas no supervisadas, se logró construir una visión empírica y multidimensional del fenómeno habitacional en Madrid durante el periodo 2011-2024. El Índice de Accesibilidad a la Vivienda (IAV) permitió integrar variables económicas, demográficas y territoriales en un único marco comparativo, aportando evidencia sobre las desigualdades habitacionales y su evolución temporal.

7.1. Cumplimiento de los objetivos del estudio

Los resultados obtenidos permiten confirmar el cumplimiento de los objetivos generales y específicos planteados:

- Se analizó el mercado inmobiliario madrileño mediante la recolección e integración de datos procedentes de fuentes oficiales y del portal Idealista, generando un panel homogéneo y representativo.

- Se desarrolló un modelo predictivo de precios (**LGBM**) optimizado con **Optuna**, que alcanzó un R^2 mayor a 0,9, demostrando una elevada capacidad explicativa y una adecuada generalización temporal.
- Se diseñó y aplicó el **Índice de Accesibilidad a la Vivienda (IAV)**, que permitió medir las **desigualdades estructurales** en el acceso habitacional a nivel distrital, diferenciando entre compra y alquiler, e identificando la **dependencia creciente de los hogares de ingreso múltiple** como estrategia de sostenibilidad residencial.
- Se exploraron **patrones de gentrificación** mediante técnicas de aprendizaje no supervisado (**UMAP y K-Means**), identificando tipologías urbanas coherentes con los procesos de revalorización observados en el IAV.
- Se implementó una **interfaz web interactiva**, que integra los resultados y permite visualizar el comportamiento del mercado inmobiliario y los indicadores de accesibilidad de forma dinámica.

7.2. Contribución del estudio

Este trabajo constituye un aporte metodológico y aplicado al campo del análisis urbano mediante ciencia de datos.

En primer lugar, integra múltiples fuentes de información en una base temporal robusta, combinando datos de mercado inmobiliario en tiempo real con indicadores oficiales y socioeconómicos. Esta integración permite analizar de manera más completa las dinámicas de precios y las desigualdades territoriales en el acceso a la vivienda.

En segundo lugar, se propone un IAV transparente, capaz de cuantificar las desigualdades territoriales y de comparar la capacidad económica de los hogares para acceder a una vivienda según régimen y distrito. Su estructura flexible permite adaptar el análisis a otras ciudades o escalas metropolitanas.

Asimismo, se introduce una metodología híbrida que combina técnicas de aprendizaje supervisado y no supervisado para la detección empírica de patrones de gentrificación, permitiendo identificar procesos de revalorización urbana y sus implicaciones sociales.

Finalmente, se desarrolló una aplicación interactiva en Streamlit, que favorece la transparencia, la interpretación de resultados y la transferencia del conocimiento hacia el ámbito institucional. Esta

herramienta consolida los hallazgos del estudio en un entorno accesible y dinámico, útil para la planificación urbana basada en datos.

7.3. Reflexión final

El estudio confirma que el acceso a la vivienda en Madrid no depende únicamente del comportamiento del mercado, sino de una estructura urbana que reproduce desigualdades económicas, sociales y espaciales. El alquiler aparece como la única alternativa viable para gran parte de la población, aunque su sostenibilidad depende cada vez más de ingresos combinados y estrategias de ingreso múltiple, antes que de la solvencia individual.

En este contexto, la planificación urbana debe orientarse a restablecer el equilibrio entre vivienda, renta y territorio, mediante políticas de alquiler asequible, promoción de vivienda pública, regulación de la oferta turística y apoyo a modelos cooperativos de tenencia.

Finalmente, el trabajo demuestra que la ciencia de datos aplicada al urbanismo puede convertirse en una herramienta poderosa para diagnosticar desigualdades, anticipar tendencias y diseñar políticas basadas en evidencia, contribuyendo así a una ciudad más justa, resiliente y habitable.

8. Bibliografía

Ayuntamiento de Madrid. (2016). *La oferta de alojamiento turístico en Madrid. Características y distribución territorial*. Área de Gobierno de Desarrollo Urbano Sostenible.

Ayuntamiento de Madrid. (2021). *La ciudad de Madrid en cifras*. Obtenido de <https://www.madrid.es/UnidadesDescentralizadas/UDCEstadistica/Nuevaweb/Publicaciones/Madrid%20en%20Cifras/Madrid%20en%20cifras%202021.pdf>

Ayuntamiento de Madrid. (2023). *Compendio de las Normas Urbanísticas del Plan General de Ordenación Urbana de Madrid de 1997 - Edición 2023*. Área de Gobierno de Urbanismo, Medio Ambiente y Movilidad. Madrid: Ayuntamiento de Madrid. Obtenido de <https://transparencia.madrid.es/UnidadesDescentralizadas/UDCUrbanismo/PGOUM/CompendioNNUU/Compendio%202023/1%20Compendio%202023.pdf>

Ayuntamiento de Madrid. (2025). *1. Esperanza de vida por Distrito y Edad (grupos quinquenales) para cada Sexo*. Obtenido de Banco de Datos del Ayuntamiento de Madrid:

https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0310000000010

Ayuntamiento de Madrid. (2025). *1.2.3. Oferta de apartamentos turísticos y hotel-apartamentos en la ciudad de Madrid por Categoría, Tipo de establecimiento y Distrito*. Obtenido de Banco de Datos del Ayuntamiento de Madrid: https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=1601020000030

Ayuntamiento de Madrid. (2025). *3.1.1 Indicadores de renta media y mediana*. Obtenido de Banco de Datos del Ayuntamiento de Madrid: https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0403010000010

Ayuntamiento de Madrid. (2025). *3.2.5. Paro registrado por Distrito, Nivel formativo y Sexo, por Mes (desde 2012)*. Obtenido de Banco de Datos del Ayuntamiento de Madrid: https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0904030200050

Ayuntamiento de Madrid. (2025). *4.3.15.B. Evolución del precio de venta de la vivienda (€/m²) por Distrito (de 2006 a 2024)*. Obtenido de Banco de Datos del Ayuntamiento de Madrid: https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0504030000152

Ayuntamiento de Madrid. (2025). *4.3.21.C. Evolución del precio de alquiler de la vivienda (€/m²) por Distrito (Período: 2019-2024)*. Obtenido de Banco de Datos del Ayuntamiento de Madrid: https://servpub.madrid.es/CSEBD_WBINTER/seleccionSerie.html?numSerie=0504030000213

Ayuntamiento de Madrid. (2025). *Superficie de parques y zonas verdes de Madrid*. Obtenido de Portal de datos abiertos del Ayuntamiento de Madrid: <https://datos.madrid.es/sites/v/index.jsp?vgnextoid=559b401daf436610VgnVCM1000001d4a900aRCRD&vgnnextchannel=374512b9ace9f310VgnVCM100000171f5a0aRCRD>

Banco de España. (2024). *El mercado de la vivienda en España: evolución reciente, riesgos y problemas de accesibilidad*. Madrid. Obtenido de <https://www.bde.es/f/webbe/GAP/Secciones/SalaPrensa/IntervencionesPublicas/DirectoresGenerales/economia/Arc/IIPP-2024-11-18-gavilan-es-or.pdf>

- Cox, W., & Pavletich, H. (2024). *Demographia International Housing Affordability Survey: 2024 Edition*. Chapman University. Obtenido de <https://www.demographia.com/dhi.pdf>
- Cox, W., & Pavletich, H. (2025). *Demographia International Housing Affordability Survey: 2025 Edition*. Chapman University. Obtenido de https://www.chapman.edu/communication/_files/Demographia-International-Housing-Affordability-2025-Edition.pdf
- Eurostat. (2023). *Housing cost overburden rate*. Obtenido de Luxembourg: Statistical Office of the European Union: <https://ec.europa.eu/eurostat>
- Expansión. (2025). *Madrid - Turismo internacional*. Obtenido de Datosmacro.com: <https://datosmacro.expansion.com/comercio/turismo-internacional/espana-comunidades-autonomas/madrid?anio=2024>
- Federal Reserve Bank of San Francisco. (2003). *What is the Housing Affordability Index? Doctor Econ*. Obtenido de San Francisco: FRBSF: <https://www.nar.realtor/research-and-statistics/housing-statistics/housing-affordability-index/methodology>
- Fernández Ochoa, M. N. (2025). Factores y predicción de la gentrificación en la ciudad de Madrid. *Trabajo Fin de Máster, Universitat Oberta de Catalunya*.
- Fixr. (2025). *¿Cuál es la superficie mínima obligatoria para una vivienda en España?* Obtenido de Fixr: <https://www.fixr.es/blog/cual-es-la-superficie-minima-obligatoria-para-una-vivienda-en-espana>
- Idealista. (2025). *La vivienda en Madrid vuelve a marcar récord en agosto con una subida anual del 21,3%*. Obtenido de Idealista/news: <https://www.idealista.com/news/inmobiliario/vivienda/2025/09/03/858473-la-vivienda-en-madrid-vuelve-a-marcar-record-en-agosto-con-una-subida-anual-del-21>
- Idealista. (2025). *Madrid*. Obtenido de Idealista: <https://www.idealista.com/>
- INE. (2025). *Índice de Precios de Vivienda (IPV). Base 2015. Segundo trimestre 2025*. Obtenido de Instituto Nacional de Estadística (INE): https://www.ine.es/dyngs/INEbase/es/operacion.htm?c=Estadistica_C&cid=1254736152838&menu=ultiDatos&idp=1254735976607

- Instituto Nacional de Estadística (INE). (2025). *Indicadores demográficos*. Obtenido de Resultados por municipios, distritos y secciones censales por provincias: <https://ine.es/jaxiT3/Tabla.htm?t=31105>
- Martín Agüero, A. (2025). Modelos predictivos aplicados al mercado inmobiliario español. *Trabajo Fin de Máster, IMF Smart Education*.
- Mullor Gómez, L. (2007). *Estudio sobre los diferentes Indicadores de Accesibilidad a la vivienda*. Ministerio de Vivienda de España. Obtenido de https://www.transportes.gob.es/recursos_mfom/pdf/596C3FFE-DE6C-4486-A5F2-719A036D961C/99232/Acesibil07.pdf
- National Association of Realtors (NAR). (2022). *Housing Affordability Index: Methodology*. Obtenido de Washington, D.C.: NAR Research Group: <https://www.nar.realtor/research-and-statistics/housing-statistics/housing-affordability-index/methodology>
- Organisation for Economic Co-operation and Development (OECD). (2023). *OECD*. Obtenido de OECD Affordable Housing Database: <https://www.oecd.org/housing/data/affordable-housing-database>
- Schinasi, L. H., Cole, H. V., Hirsch, J. A., Hamra, G. B., Gullon, P., Bayer, F., . . . Lovasi, G. S. (2021). Associations between greenspace and gentrification-related sociodemographic and housing cost changes in major metropolitan areas across the United States. *International Journal of Environmental Research and Public Health*, 18(6). doi:10.3390/ijerph18063315
- Smith, N. (1979). Toward a theory of gentrification: A back to the city movement by capital, not people. *Journal of the American Planning Association*, 45(4), 538-548. doi:10.1080/0194436790897702
- UN-Habitat. (2024). *Cities and Climate Action - World Cities Report 2024*. Obtenido de https://unhabitat.org/sites/default/files/2024/11/wcr2024_-_full_report.pdf
- World Bank & United Nations Centre for Human Settlements (UNCHS). (1993). *Housing: Enabling Markets to Work*. Obtenido de Washington, D.C.: The World Bank: <https://openknowledge.worldbank.org/handle/10986/15433>
- Zukin, S. (1987). Gentrification: Culture and capital in the urban core. *Annual Review of Sociology*, 13(1), 129-147. doi:10.1146/annurev.so.13.080187.001021

9. Anexos

9.1. Anexo A. Proceso técnico de extracción de datos desde Idealista

9.1.1. Objetivo

El objetivo del script es automatizar la recolección de información de viviendas en venta y alquiler en Madrid, clasificadas por distrito, para construir una base de datos estructurada y comparable en el tiempo.

9.1.2. Entorno de ejecución

- **Lenguaje:** Python 3.12
- **Librerías principales:**
 - BeautifulSoup4 → parseo del HTML.
 - requests → conexión HTTP (incluido en fetch_page).
 - selenium-y undetected_chromedriver→ webscraping.
 - os → carga de variables de entorno.
 - csv → almacenamiento de resultados.
- **Otras dependencias:** random, time.
- **Ejecución recomendada:**

```
python -m src.webscraping.scraprer
```

9.1.3. Variables de entorno

El archivo .env contiene las variables necesarias para parametrizar la ejecución:

DISTRICTS=centro,chamberi,retiro,usera,...

- DISTRICTS: lista de distritos a procesar, separados por coma.

9.1.4. Parámetros de ejecución

Al iniciar el script, se piden al usuario los siguientes parámetros en consola:

- **Página inicial** → índice desde donde arrancar el scraping.
- **Página final** → última página a procesar.
- **Modo** → 1 = venta, 2 = alquiler.
- **Stealth mode** → permite reducir la probabilidad de detección por el portal.
- **Modo rápido** → acorta las esperas, con más riesgo de bloqueo.

9.1.5. Datos extraídos

Para cada anuncio se capturaron:

- precio (precio en euros).
- localidad (barrio/dirección abreviada).
- tamaño (superficie en m²).
- habitaciones (número de dormitorios).
- descripción (resumen breve).
- link (URL del anuncio).
- descripción_larga (texto ampliado del anuncio).
- distrito (campo añadido al consolidar).

9.1.6. Salidas del proceso

- **CSV por distrito:**
data/webscraping/csv/distrito_{distrito}_{venta|alquiler}_pags_{i}-{f}.csv
- **CSV consolidado:**
data/raw/properties_all_{venta|alquiler}_pags_{i}-{f}.csv

Todos los ficheros se generan en codificación UTF-8 y separados por ;.

9.1.7. Estrategias anti-bloqueo

- **Cache local:** cada página HTML se guarda en data/webscraping/cached_pages/ para su reutilización y trazabilidad.
- **Retrasos aleatorios** (random_sleep): entre 15–45 segundos por página (ajustable).
- **Backoff progresivo** (progressive_sleep): esperas más largas tras errores consecutivos.
- **Stealth mode:** oculta ciertos patrones de tráfico para reducir bloqueos.

9.1.8. Buenas prácticas

- El scraping se realizó con fines exclusivamente académicos.
- Se respetaron intervalos de espera para evitar sobrecargar el portal.
- No se procesó ni almacenó información personal de usuarios.
- Los datos se analizaron de forma agregada por distrito, garantizando el carácter anónimo del estudio.

9.2. Anexo B. Repositorio de GitHub

El proyecto se realizó utilizando un repositorio de GitHub, que presenta la siguiente estructura:




Figura 45. Diagrama del repositorio de GitHub.

En la carpeta “app” se introdujo lo necesario para la interfaz web de Streamlit; en “data”, los datos obtenidos de diversas fuentes y procesados en diferentes fases; dentro de “data”, en “webscraping”, se incluyen las páginas web en caché y los archivos csv generados; en “models” se incluyen los archivos exportados de modelado; en “notebooks”, los archivos de notebook de Python, como el EDA o los clústeres; en “reports” se incluyen reportes básicos, y dentro de “figures”, las imágenes y

gráficos generados; en “src”, scripts ejecutables de Python, con la carpeta “webscraping” para el software del scraping; y en “utils”, scripts de Python que contienen funciones definidas para su uso en otros archivos.

Los archivos sueltos del repositorio son los generados propiamente para el control de versiones y para requerimientos del sistema.

El repositorio es accesible a través de la página web oficial de GitHub, en el siguiente enlace:
https://github.com/JorgeGM8/TFM_Data_Science